

# 专家干预下置信规则库参数训练的差分进化算法

王韩杰<sup>1</sup> 杨隆浩<sup>1</sup> 傅仰耿<sup>1</sup> 吴英杰<sup>1</sup> 巩晓婷<sup>2</sup>

(福州大学数学与计算机科学学院 福州 350116)<sup>1</sup> (福州大学经济与管理学院 福州 350116)<sup>2</sup>

**摘 要** 传统关于置信规则库参数训练模型的求解主要采用 FMINCON 函数及群智能算法,但在算法设计中并未涉及所有的置信规则库参数,且缺少必要的专家干预。为解决这些问题,首先在现有参数模型的基础上进一步扩宽参与参数训练的置信规则库参数,然后设计出符合思维逻辑的专家干预的约束条件,最后结合差分进化算法提出具有更高收敛精度的置信规则库参数训练方法。在实验分析中,首先在多极值函数的实例中分析该方法的有效性,再在输油管道检漏的实例中检验专家干预的合理性及对比现有的其他参数训练方法。实验结果表明,该方法是有可行性的。

**关键词** 置信规则库,参数训练,差分进化算法,专家干预

**中图分类号** TP183 **文献标识码** A **DOI** 10.11896/j.issn.1002-137X.2015.5.018

## Differential Evolutionary Algorithm for Parameter Training of Belief Rule Base under Expert Intervention

WANG Han-jie<sup>1</sup> YANG Long-hao<sup>1</sup> FU Yang-geng<sup>1</sup> WU Ying-jie<sup>1</sup> GONG Xiao-ting<sup>2</sup>

(College of Mathematics and Computer Science, Fuzhou University, Fuzhou 350116, China)<sup>1</sup>

(College of Economics and Management, Fuzhou University, Fuzhou 350116, China)<sup>2</sup>

**Abstract** Traditionally, FMINCON function and swarm intelligence algorithms are adopted to search for solutions of training model about the parameters of belief rule base (BRB) system. However, all the parameters of BRB system are not involved in these training processes, and there is a lack of the necessary intervention from the experts in these algorithms. In view of these, firstly, the parameters of BRB system were further broadened on the basis of the existing models. Then, the logical constraints under the expert intervention were designed. Finally, the new training method for BRB system with better convergent accuracy which is combined with the differential evolutionary algorithm was proposed. In the experiment analysis of the new approach, the effectiveness was validated via the example of a multi-extreme function, and the rationality was examined under the expert intervention in the example of pipeline leak detection by comparing with the existing approaches of parameter training. The results show that the proposed method is effective and feasible.

**Keywords** Belief rule base, Parameter training, Differential evolutionary algorithm, Expert intervention

## 1 引言

基于证据推理算法的置信规则库推理方法 (belief rule-base inference methodology using the evidence reasoning approach, RIMER) 由 Yang 等<sup>[1]</sup> 首次提出, 涵盖了 D-S 证据理论<sup>[2,3]</sup>、决策理论<sup>[4]</sup>、模糊理论<sup>[5]</sup> 和传统 IF-THEN 规则库<sup>[6]</sup> 等的基础知识, 因此该方法能够有效地利用不完整或不精确的信息对复杂决策问题进行建模。目前, 以 RIMER 为核心的置信规则库 (Belief Rule Base, BRB) 系统已得到广泛应用, 主要包括输油管道检漏<sup>[7]</sup>、石墨成分检测<sup>[8]</sup> 和军事能力评估<sup>[9]</sup> 等工程领域。

BRB 系统的推理性能主要依靠其内部参数的取值, 当实

际决策问题较为复杂时, 由专家给定参数初值的方式将无法保证 BRB 系统的推理准确性。为解决该问题, 可根据获得的有效信息, 并结合参数训练模型优化初始 BRB 系统中内部的参数, 进而提高 BRB 系统的推理准确性。目前, 用于求解参数训练模型的方法有多种, 主要包括: FMINCON 函数<sup>[9]</sup>、梯度下降法<sup>[10]</sup> 和群智能算法<sup>[11]</sup> 等。其中, Yang 等<sup>[8]</sup> 提出的使用 Matlab 中 FMINCON 函数进行参数训练的方法, 收敛速度慢, 且收敛精度不高; 常瑞等<sup>[10]</sup> 提出的基于梯度法和二分法的参数训练方法及 Chang 等<sup>[12]</sup> 提出的基于差分进化算法的参数训练方法, 均仅对 BRB 系统的部分参数进行训练。此外, 上述的参数训练方法均缺少必要的专家干预策略。虽然 Zhou 等<sup>[7]</sup> 在输油管道检漏的实例中首次引入专家干预策略,

到稿日期: 2014-01-29 返修日期: 2014-04-12 本文受国家自然科学基金青年项目 (61300026, 61300104), 国家杰出青年科学基金项目 (70925004), 国家自然科学基金面上项目 (71371053), 福建省自然科学基金项目 (2015J01248), 福建省教育厅 A 类科技项目 (JA13036), 福州大学科技发展基金项目 (2014-XQ-26) 资助。

王韩杰 (1992—), 男, 硕士生, 主要研究方向为智能决策技术、置信规则库推理等, E-mail: 123054228@qq.com; 杨隆浩 (1990—), 男, 硕士生, 主要研究方向为智能决策技术、置信规则库推理等; 傅仰耿 (1981—), 男, 博士, 讲师, 主要研究方向为不确定多准则决策、置信规则库推理、移动互联网应用等; 吴英杰 (1979—), 男, 博士, 副教授, 主要研究方向为数据挖掘、数据安全与隐私保护等; 巩晓婷 (1982—), 女, 硕士, 讲师, 主要研究方向为不确定多准则决策、信息隐藏技术等, E-mail: xtgong@126.com。

但该专家干预策略仅确保了规则间的结果置信度的关联关系,而忽略了规则内的结果置信度的关联关系,因此参数训练后各规则内的结果置信度分布依旧杂乱;同时还假设不会出现最大泄漏量,致使训练效果一般。

鉴于此,本文在差分进化(Differential Evolutionary, DE)算法的基础上,首先扩宽参与参数训练的置信规则库参数,并给出新增参数的适用于 DE 算法的约束条件;然后提出合理的专家干预策略,使训练后的置信规则的置信度主要集中于某个区间上,进而更加符合决策者的决策习惯;最后再整合新参数训练模型和专家干预策略,提出专家干预下置信规则库参数训练的差分进化算法。为验证本文方法的有效性,在实验分析中引入多极值函数和输油管道检漏两个实例,其中在多极值函数实例中,以均方差(Mean Squared Error, MSE)公式作为参数训练模型中的目标函数,验证本文方法能够对一般的 BRB 进行参数训练;在输油管道检漏实例中,以平均绝对误差(Mean Absolute Error, MAE)公式作为参数训练模型中的目标函数,验证本文方法在实际问题中的适用性。

## 2 RIMER 方法与参数训练

BRB 系统中的基础知识主要有 RIMER 方法和参数训练,其中 RIMER 方法包括 BRB 的表示及 BRB 的推理机制。

### 2.1 BRB 的表示

BRB 中包含若干条置信规则,而置信规则是由传统 IF-THEN 规则扩展而来,其除了新增分布式置信框架外,还加入了规则权重和前提属性权重。其中第  $k$  条置信规则表示如下:

$$\begin{aligned} R_k: & \text{if } X_1 \text{ is } A_1^k \wedge X_2 \text{ is } A_2^k \wedge \dots \wedge X_{T_k} \text{ is } A_{T_k}^k \\ & \text{then } \{(D_1, \bar{\beta}_{1,k}), (D_2, \bar{\beta}_{2,k}), \dots, (D_N, \bar{\beta}_{N,k})\} \\ & \text{With a rule weight } \theta_k \text{ and attribute weight } \bar{\delta}_1, \bar{\delta}_2, \dots, \bar{\delta}_{T_k} \end{aligned} \quad (1)$$

式中,  $X_i$  表示第  $i$  个前提属性,  $T_k$  ( $k=1, \dots, L$ ) 表示第  $k$  条规则中前提属性的数量,  $L$  表示置信规则库中规则的数量;  $A_i^k$  表示第  $k$  条规则中第  $i$  个前提属性的候选值;  $\bar{\beta}_{i,k}$  表示第  $k$  条规则中第  $i$  个评价等级的置信度,  $N$  表示评价等级的数量;  $\theta_k$  表示第  $k$  条规则的规则权重;  $\bar{\delta}_i$  表示第  $i$  个前提属性的前提属性权重。当  $\sum_{i=1}^{T_k} \bar{\beta}_{i,k} = 1$  时,表示第  $k$  条规则包含的信息是完整的,否则表示包含的信息是不完整的。

### 2.2 BRB 的推理机制

RIMER 方法的推理过程主要包含两个步骤,分别为激活权重的计算及置信度的修正和激活规则的合成。

#### 2.2.1 激活权重的计算及置信度的修正

当 BRB 系统的输入值为  $x$  时,第  $k$  条规则激活权重的计算公式表示如下:

$$\begin{aligned} \omega_k &= \frac{\theta_k \prod_{i=1}^{T_k} (\alpha_i^k)^{\bar{\delta}_{k,i}}}{\sum_{i=1}^L [\theta_i * \prod_{i=1}^{T_k} (\alpha_i^i)^{\bar{\delta}_{i,i}}]} \\ \bar{\delta}_{k,i} &= \frac{\delta_{k,i}}{\max_{i=1, \dots, T_k} \{\delta_{k,i}\}} \end{aligned} \quad (2)$$

其中,  $\theta_k$  表示第  $k$  条规则的规则权重;  $\delta_{k,i}$  表示第  $k$  条规则的第  $i$  个前提属性权重;  $\alpha_i^k$  表示第  $k$  条规则中第  $i$  个前提属性的候选值对应的个体匹配度。由于输入值可能不完整,因此

需要对规则结果集的置信度进行修正,修正公式如下:

$$\beta_{i,k} = \bar{\beta}_{i,k} \frac{\sum_{t=1}^{T_k} (\tau(t,k) \sum_{j=1}^{J_t} \alpha_{t,j})}{\sum_{t=1}^{T_k} \tau(t,k)} \quad (3)$$

$$\tau(t,k) = \begin{cases} 1, & U_t \in R_k, t=1, \dots, T_k \\ 0, & \text{otherwise} \end{cases}$$

#### 2.2.2 激活规则的合成

激活规则的合成主要是使用证据推理(Evidential Reasoning, ER)算法<sup>[1]</sup>。首先,由激活规则结果集的置信度和激活权重计算基本可信值:

$$m_{j,k} = \omega_k \beta_{j,k} \quad (4)$$

$$\tilde{m}_{D,k} = \omega_k (1 - \sum_{j=1}^N \beta_{j,k}) \quad (5)$$

$$\bar{m}_{D,k} = 1 - \omega_k \quad (6)$$

然后,使用 ER 的解析公式<sup>[13]</sup>将所有的激活规则一次合成,合成公式如下:

$$C_j = k [\prod_{l=1}^L (m_{j,l} + \bar{m}_{D,l} + \tilde{m}_{D,l}) - \prod_{l=1}^L (\bar{m}_{D,l} + \tilde{m}_{D,l})] \quad (7)$$

$$\tilde{C}_D = k [\prod_{l=1}^L (\bar{m}_{D,l} + \tilde{m}_{D,l}) - \prod_{l=1}^L \bar{m}_{D,l}] \quad (8)$$

$$\bar{C}_D = k \prod_{l=1}^L \bar{m}_{D,l} \quad (9)$$

$$k^{-1} = \sum_{j=1}^N \prod_{l=1}^L (m_{j,l} + \bar{m}_{D,l} + \tilde{m}_{D,l}) - (N-1) \prod_{l=1}^L (\bar{m}_{D,l} + \tilde{m}_{D,l}) \quad (10)$$

接着,计算各个评价等级上的置信度:

$$\beta_j = \frac{C_j}{1 - \bar{C}_D}, n=1, \dots, N \quad (11)$$

$$\beta_D = \frac{\bar{C}_D}{1 - \bar{C}_D} \quad (12)$$

最后,计算 BRB 系统的期望效用值,假设等级效用值  $\mu = \{\mu_1, \mu_2, \dots, \mu_N\}$ ,则计算公式为:

$$\mu_{\min} = (\beta_1 + \beta_D) \mu_1 + \sum_{j=2}^N \beta_j \mu_j \quad (13)$$

$$\mu_{\max} = (\beta_N + \beta_D) \mu_N + \sum_{j=1}^{N-1} \beta_j \mu_j \quad (14)$$

$$\mu_{\text{avg}} = \frac{\mu_{\min} + \mu_{\max}}{2} \quad (15)$$

### 2.3 参数训练模型

BRB 系统的参数初值通常是由专家根据历史信息和先验知识给定,具有主观局限性。鉴于此, Yang 等<sup>[8]</sup>首先提出对 BRB 系统进行参数训练,其基本思想是:利用实际系统的输入和输出值矫正 BRB 系统的初始参数,进而提高 BRB 系统的推理性能。其中参数训练模型<sup>[14]</sup>如图 1 所示。




图 1 BRB 系统参数训练模型

图 1 中参数训练模型的符号表达式如下所示:

$$\begin{aligned} & \min \{\xi(P)\} \\ & \text{s. t. } A(P) = 0, B(P) \geq 0 \end{aligned} \quad (16)$$

其中,  $P$  是待训练的参数向量  $P = (\beta_{i,k}, \theta_k, \delta_i)$ ;  $\xi(P)$  表示实际系统观测输出与 BRB 系统推理输出之间的差值;当  $\xi(P)$  越小时,表明该 BRB 系统能够越准确地模拟实际系统的行为,而最小化  $\xi(P)$  则是 BRB 系统参数训练的目的。在参数训练

过程中,同时还需合理的等式约束条件  $A(P)$  和不等式约束条件  $B(P)$ ,对此,Yang 给出如下说明:

1) 标准化规则权重  $\theta_k$ ,使其不小于 0 或不大于 1,即:

$$0 \leq \theta_k \leq 1, k=1, 2, \dots, L \quad (17)$$

2) 标准化前提属性权重  $\bar{\delta}_i$ ,使其不小于 0 或不大于 1,

即:

$$0 \leq \bar{\delta}_i \leq 1, i=1, 2, \dots, M \quad (18)$$

其中,  $M$  表示 BRB 中前提属性的数量。

3) 任意一条置信规则的结果置信度均不小于 0 或不大于 1,其中第  $k$  条规则的第  $j$  个评价等级上的置信度需满足:

$$0 \leq \beta_{j,k} \leq 1, j=1, 2, \dots, N, k=1, 2, \dots, L \quad (19)$$

4) 假设第  $k$  条规则是完整的,即输入不包含不确定、模糊信息,则该条规则的结果置信度之和等于 1,即:

$$\sum_{j=1}^N \beta_{j,k} = 1, k=1, 2, \dots, L \quad (20)$$

## 2.4 问题提出

目前,针对求解参数训练模型的可用方法主要有:Yang 等<sup>[8]</sup>提出的基于 Matlab 中 FMINCON 函数的参数训练方法,该类方法的参数训练结果在收敛速度和精度上均不理想;常瑞等<sup>[10]</sup>基于梯度法和二分法提出参数训练的联合算法,该方法虽然有效地提高了收敛速度,但仅局限于对 BRB 系统部分参数进行参数训练;Chang 等<sup>[12]</sup>引入群智能算法,提出基于差分进化算法的参数训练方法,但该方法同样仅对 BRB 系统的部分参数进行训练。另外,上述的训练方法均表现出一个共同的特点,即经参数训练后各条置信规则结果置信度的分布均杂乱无章,致使出现不符合常理的置信规则。诸如文献<sup>[15]</sup>的表 A-III 中第 13、14、19 和 20 条规则,由于未引入专家干预策略,因此置信规则之间的结果置信度表现出无关联性,且规则内的结果置信度也无合理分布,针对相同的输入,还会同时出现最小泄漏量和最大泄漏量的情况,即呈现单波谷分布。

为解决该问题,Zhou 等<sup>[7]</sup>首先引入专家干预的概念,提出通过增加参数训练时的约束条件来规范经训练后各条置信规则结果置信度的分布,并将其应用在输油管道检漏的实例中。该专家干预策略主要反映规则之间的相互关联,但这种关联只涉及到规则间的结果置信度,忽略了规则内结果置信度的相互关联,导致参数训练后结果置信度的分布仍旧无章可循,并提出不会出现最大泄漏量的绝对性假设,与实际不符。鉴于此,本文首先从规则内的结果置信度相互关联的角度入手,确保参数训练后结果置信度分布更加符合决策者的决策习惯,而不至于出现无章可循的分布;然后提出改进的参数训练模型,增加参数训练时涉及的 BRB 参数;最后在此基础上提出专家干预下置信规则库参数训练的差分进化算法。

## 3 专家干预下基于 DE 的参数训练方法

### 3.1 差分进化算法

差分进化(Differential Evolutionary, DE)算法<sup>[11]</sup>是人们受适者生存进化规律的启发而提出的一种进化算法。该算法是基于种群的启发式全局搜索技术,受控参数少且具有强鲁棒性,是解决复杂优化问题的有效技术<sup>[16,17]</sup>。同时,算法中利用种群中差分扰动向量来产生新个体,因此可获得一个收敛性较好的结果<sup>[18]</sup>。其中,DE 算法的流程如下:

步骤 1 初始化种群。确定种群数量和进化代数,随机

生成初始化种群。

步骤 2 变异操作。通过差分方法实现个体变异:从初始种群中随机抽取 3 个不同个体,再将两个个体参数向量的差值通过常数缩放后与待变异个体的参数向量进行合成,产生变异中间个体。变异公式如下:

$$v_i = x_{r_1} + F * (x_{r_2} - x_{r_3}) \quad (21)$$

其中,  $r_1, r_2, r_3$  是随机整数,并满足  $r_1 \neq r_2 \neq r_3$ ,  $F$  是常量,一般取值为  $F=0.5$ 。

步骤 3 交叉操作。根据交叉概率,对变异中间个体与当前个体做个体间的交叉操作,产生交叉中间个体。交叉公式如下:

$$u_i(j) = \begin{cases} v_i(j), & \text{if } rand \leq CR \\ x_i(j), & \text{otherwise} \end{cases} \quad (22)$$

其中,  $rand$  表示  $(0, 1)$  区间均匀分布的随机数,  $CR$  是交叉概率,一般取值为  $CR=0.9$ 。

步骤 4 选择操作。采用贪婪策略来选择种群中下一代个体,常用的选择指标为 MAE 和 MSE。其中,选择公式如下:

$$x_i' = \begin{cases} u_i, & \text{if } f(u_i) \leq f(x_i) \\ x_i, & \text{otherwise} \end{cases} \quad (23)$$

步骤 5 循环操作。当种群的进化代数未达到事先设定的进化代数时,循环执行步骤 2—4;否则,算法结束。

### 3.2 专家干预的策略

针对现有专家干预策略中忽略规则内结果置信度的关系,本文提出了一种新的专家干预策略。相对于 Zhou 的专家干预策略,其更适合于与 DE 算法相结合,并取得更理想的参数训练结果。其中专家干预的依据是:在实际问题的决策中,人们的最终决策结果通常是偏重于某个方面,而较少出现相互矛盾的决策结果,例如在输油管道检漏问题中,依据输入值可直观地判定输油管道漏洞大小,而不会得出无漏洞和漏洞非常大两者同时存在的决策结果,即在参数训练后的置信规则结果置信度分布中应呈现单波峰分布。因此本文提出的新策略为:在 DE 算法的每次迭代中,为达到让置信度的取值能够满足系统工作模式的目的,在 DE 算法的交叉操作后,将规则内结果置信度按照特定逻辑进行重分配,使其主要集中于某个等级上,呈现单波峰分布,进而更符合决策者的决策习惯。给出如下约束条件进行专家干预,其中第  $k$  条规则的第  $m$  个结果置信度应满足:

$$\beta_{m,k} = \max\{\beta_{i,k} | i \in [1, N]\} \quad (24)$$

$$\beta_{i,k} \leq \beta_{i+1,k}, i < m \quad (25)$$

$$\beta_{i,k} \geq \beta_{i+1,k}, i > m \quad (26)$$

### 3.3 新参数训练方法

根据 DE 算法和专家干预的新策略,本文提出一种专家干预下基于参数训练的 DE 算法。相比于 Yang 的参数训练模型<sup>[14]</sup>,本文新增前提属性候选值和评价等级的效用值作为训练参数。由于 DE 算法在交叉操作中对不满足交叉概率的参数均进行随机赋值,因此传统的约束条件不再适合本文方法。为此,给出符合 DE 算法的新增参数的约束条件:

(1) 假设初始 BRB 的第  $i$  个前提属性候选值为  $\bar{A}_i = \{\bar{A}_{i,1}, \bar{A}_{i,2}, \dots, \bar{A}_{i,J}\}$ ,  $J$  为候选值个数。当对第  $i$  个前提属性候选值进行参数训练时,固定其候选值区间端点值,使用初始候选值集合的元素约束生成新候选值集合元素,即:

$$\bar{A}_{i,j-1} < A_{i,j} < \bar{A}_{i,j+1}, j=2,3,\dots,J-1 \quad (27)$$

再按照升序排列新的候选值集合,得到  $A_i = \{\bar{A}_{i,1}, A_{i,2}, \dots, A_{i,J-1}, \bar{A}_{i,J}\}$ 。

(2)假设初始 BRB 的等级效用值为  $\bar{D} = \{\bar{D}_1, \bar{D}_2, \dots, \bar{D}_N\}$ 。当对等级效用值进行训练时,同样固定等级效用值区间端点值,使用初始等级效用值集合的元素约束生成新等级效用值集合元素,即:

$$\bar{D}_{i-1} < D_i < \bar{D}_{i+1}, i=2,3,\dots,N-1 \quad (28)$$

再按照升序排列新的等级效用值,得到  $D = \{\bar{D}_1, D_2, \dots, D_{N-1}, \bar{D}_N\}$ 。

DE 算法在变异的过程中,会产生不满足初始约束条件的参数,此时对其进行随机赋值。由于交叉过程本身具有随机性质,因此随机赋值并不会对算法产生影响。而重新产生的参数也遵循特定的约束条件。

本文方法的算法流程如图 2 所示,其算法步骤如下:

步骤 1 随机方式初始化种群中的各个个体,其中每个个体独立包含 BRB 的所有参数,随机初始化过程中必须严格遵循等式及不等式约束条件。

步骤 2 使用本文专家干预策略调整结果置信度,并计算初始种群中各个个体的适应度。

步骤 3 按照 DE 算法的流程对种群中各个个体进行变异操作、交叉操作和选择操作,其中在交叉操作中,使用本文专家干预策略调整不在约束条件之内的参数值。

步骤 4 若种群的进化代数未达到事先设定的进化代数,循环执行步骤 3;否则,输出全局最优个体的参数值,算法结束。

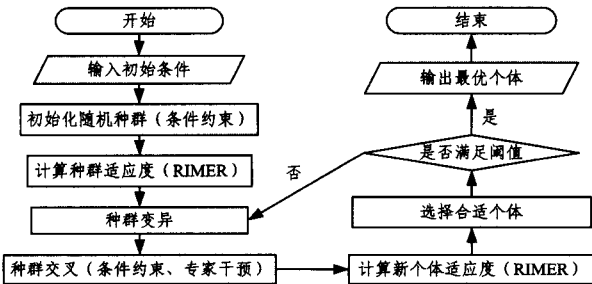


图 2 基于 DE 算法的参数训练方法流程

#### 4 实验分析与性能比较

本节将从参数训练方法的有效性和效率两方面进行实验研究,并分别对比利用 FMINCON 函数的参数训练方法<sup>[8]</sup>及基于梯度下降法的参数训练方法<sup>[10]</sup>。实验中,除利用 FMINCON 函数的参数训练方法是在 Matlab R2012b 中实现外,其余方法均在 VC++6.0 中实现。为克服算法中的随机特性且增加实验结果的说服力,实验中均采取独立运行 50 次的方式获取实验结果。此外,实验环境的基本信息为: Intel(R) Core(TM) i3-3210 CPU @ 3.20GHz 处理器、4GB 内存, Windows 7 操作系统。

##### 4.1 多极值函数实例

为验证本文方法能够对一般的 BRB 进行参数训练,首先引入一个多极值函数,函数表达式如下:

$$g(x) = e^{-(x-2)^2} + 0.5e^{-(x+2)^2} \quad (29)$$

由文献[19]可知,通过选取多极值函数中的极值点,可构建由 5 条规则组成的 BRB,如表 1 所列。

表 1 初始置信规则库

规则编号	规则权重	候选值	$g(x)$	结果集
1	1	-5	0.0001	$\{(D_1, 0), (D_2, 0.9999), (D_3, 0.0001), (D_4, 0), (D_5, 0)\}$
2	1	-2	0.5000	$\{(D_1, 0), (D_2, 0), (D_3, 1), (D_4, 0), (D_5, 0)\}$
3	1	0	0.0275	$\{(D_1, 0), (D_2, 0.9500), (D_3, 0.0500), (D_4, 0), (D_5, 0)\}$
4	1	2	1.0000	$\{(D_1, 0), (D_2, 0), (D_3, 0), (D_4, 1), (D_5, 0)\}$
5	1	5	0.0001	$\{(D_1, 0), (D_2, 0.9998), (D_3, 0.0002), (D_4, 0), (D_5, 0)\}$

利用初始 BRB 系统拟合多极值函数,其结果如图 3 所示。




图 3 初始 BRB 系统与多极值函数的比较

图 3 中,初始 BRB 系统并不能准确地拟合多极值函数,因此需要对初始的 BRB 系统进行参数训练。在参数训练中,由多极值函数定义域上均匀地选取 1000 值作为训练数据,并规定种群数量为 100,进化代数为 1000,以 MSE 作为粒子的选择指标。训练后的 BRB 如表 2 所列,专家干预下训练所得的置信规则结果置信度呈现出波峰分布形式。

表 2 训练后的置信规则库

规则编号	规则权重	候选值	结果集
			$\{D_1, D_2, D_3, D_4, D_5\} = \{-0.5000, -0.2671, 0.1801, 0.8737, 1.5000\}$
1	0.9687	-5.0000	$\{(D_1, 0.2295), (D_2, 0.4180), (D_3, 0.1603), (D_4, 0.1603), (D_5, 0.0319)\}$
2	0.3493	-2.0470	$\{(D_1, 0.0487), (D_2, 0.0692), (D_3, 0.4992), (D_4, 0.1915), (D_5, 0.1914)\}$
3	0.4356	-0.1180	$\{(D_1, 0.2044), (D_2, 0.3174), (D_3, 0.3396), (D_4, 0.0852), (D_5, 0.0535)\}$
4	0.2940	2.0539	$\{(D_1, 0.0586), (D_2, 0.0624), (D_3, 0.1064), (D_4, 0.2145), (D_5, 0.5581)\}$
5	0.7999	5.0000	$\{(D_1, 0.0686), (D_2, 0.4841), (D_3, 0.3447), (D_4, 0.1025), (D_5, 0.0000)\}$

利用经本文方法训练后的 BRB 系统拟合多极值函数,如图 4 所示。




图 4 DE 算法参数训练结果

图 4 中,训练后的 BRB 系统能够准确地拟合多极值函数。进一步比较本文方法与现有其他方法对 BRB 系统推理性能的影响,选取 2013 年 Chen 的方法<sup>[19]</sup>作为比较对象,各方法的误差对比如图 5 所示。




图5 参数训练方法间的误差对比

图5中,相比于初始的BRB系统,本文方法和Chen方法都有效地降低了BRB系统的MSE,而在两个方法的对比中,与本文方法相关的MSE曲线的波动幅度明显小于与Chen方法相关的MSE曲线。定量分析各个方法的MSE,其中使用Chen方法训练后的MSE为 $6.3228 \times 10^{-5}$ ,而使用本文方法训练后的BRB系统的MSE为 $3.9284 \times 10^{-5}$ ,相对缩小了37.87%。

另外,当不对前提属性参考值和评价等级的效用值进行参数训练时,得到如表3所列的BRB系统,其MSE为 $7.0543 \times 10^{-5}$ ,本文方法相对其缩小了44.31%。

表3 局部参数训练后的BRB系统

规则编号	规则权重	候选值	结果集 $\{D_1, D_2, D_3, D_4, D_5\} = \{-0.5, 0, 0.5, 1, 1.5\}$
1	0.9096	-5	$\{(D_1, 0.5347), (D_2, 0.1800), (D_3, 0.1178), (D_4, 0.1043), (D_5, 0.0632)\}$
2	0.3267	-2	$\{(D_1, 0.0850), (D_2, 0.2189), (D_3, 0.4327), (D_4, 0.1366), (D_5, 0.1269)\}$
3	0.3743	0	$\{(D_1, 0.3137), (D_2, 0.3836), (D_3, 0.2457), (D_4, 0.0507), (D_5, 0.0064)\}$
4	0.2533	2	$\{(D_1, 0.0451), (D_2, 0.0683), (D_3, 0.1620), (D_4, 0.2900), (D_5, 0.4345)\}$
5	0.7058	5	$\{(D_1, 0.3368), (D_2, 0.4211), (D_3, 0.1836), (D_4, 0.0477), (D_5, 0.0137)\}$

## 4.2 输油管道检漏实例

为验证本文方法在实际问题中的适用性,本文还引入了输油管道检漏实例<sup>[7]</sup>。该实例是以安装在英国一条100多km长的输油管道为研究对象,由于实例中的数据完全来源于实际,因此该实例已先后被Yang<sup>[15]</sup>、Xu<sup>[20]</sup>、Zhou<sup>[7]</sup>等用于检测BRB参数训练方法的有效性。以下对输油管道检漏实例作简要的说明。

首先,由输油管道检漏的实例中抽取输出流量差(Flow Difference, FD)和输油管道内平均压力(Pressure Difference, PD)作为BRB的前提属性,而泄漏量的大小(Leak Size, LS)作为结果集,其中前提属性FD、PD和结果集LS量化后的候选值为:

$$FD = \{-10, -5, -3, -1, 0, 1, 2, 3\} \quad (28)$$

$$PD = \{-0.042, -0.025, -0.01, 0, 0.01, 0.025, 0.042\} \quad (29)$$

$$LS = \{0, 2, 4, 6, 8\} \quad (30)$$

为减少训练方法与训练数据间的关联性,本文从正常情况到发生25%泄漏情况的2008组数据中随机选取500组作为训练数据;规定种群中粒子数量为100,进化代数数为1000,以MAE作为选择指标。

接着,本文选取文献<sup>[15]</sup>中由专家给出的56条规则作为输油管道检漏的初始BRB,使用本文方法对初始BRB系统进行参数训练,并以2008组数据作为测试数据检测训练前后

BRB系统的推理性能,经参数训练后的拟合情况如图6所示。




图6 BRB拟合输油管道泄漏结果

由图6可知,对于专家给定的初始BRB系统,在输油管道未发生泄漏时,其推理准确性较高,但输油管道在发生泄漏时,其估计值与实际值偏差较大,这表明由专家设置的BRB系统不具备处理复杂问题的推理能力。而经本文方法训练后的BRB系统,相对于初始BRB系统,其不仅在未发生泄漏时推理准确性较高,而且在发生泄漏时拟合情况良好,虽然部分区域存在波动现象,但总体上解决了初始BRB系统推理准确性不高的问题。

### 4.2.1 专家干预的性能对比

为验证本文方法中专家干预策略的有效性,在基于DE的参数训练方法的基础上,分别比较不添加专家干预、添加Zhou的专家干预和添加本文的专家干预的参数训练方法对BRB系统推理准确性的影响,其拟合输油管道泄漏的情况如图7所示。




图7 不同专家干预参数训练结果对比

图7中,在不添加专家干预的训练结果时,BRB能够大致拟合泄漏情况,但是拟合效果很差,尤其在未发生泄漏时,波动很大,与真实情况差异明显;添加Zhou的专家干预策略,训练后拟合效果有所改善,但在未发生泄漏时,仍有波动情况,而在发生泄漏时的拟合情况仍需进一步改善;添加本文的专家干预策略,训练后拟合效果良好,且明显优于前两者,解决了在未发生泄漏时出现波动的异常,尤其在发生泄漏时拟合情况改善显著。

不同专家干预参数训练MAE的对比结果如表4所列。

表4 不同专家干预参数训练MAE的对比结果

专家干预方式	无专家干预	Zhou专家干预	本文专家干预
MAE	0.2504	0.1734	0.1653

由表4可知,3种不同专家干预下的MAE分别为0.2504、0.1734和0.1653。其中本文专家干预的参数训练方法,相对于前面两种无专家干预和Zhou专家干预的方式,其MAE分别缩小了33.99%和4.87%。这表明本文提出的专

家干预方法是可行有效的,且较 Zhou 的专家干预能得到更高的推理准确性。

4.2.2 训练方法的性能对比

将本文参数训练方法与 2009 年 Zhou 论文中使用 FMINCON 函数和 2011 年 Chang 论文中基于梯度下降法 (Gradient descent method, GDA)<sup>[10]</sup> 的参数训练方法进行分析对比,各方法拟合输油管道泄漏的情况如图 8 所示。




图 8 不同方法参数训练结果对比

图 8 中,不同参数训练方法均能得到理想结果,与真实数据拟合良好。但基于 GDA 的训练方法,训练后局部会出现异常波动,这与数据选取有关;使用 FMINCON 函数进行参数训练后,在未发生泄漏时,仍有少量波动;本文方法相较于另外两种方法,拟合情况更佳,出现异常波动的情况较少。此外,收敛精度和时间如表 5 所列,可见本文方法不仅能够得到更好的收敛精度,而且收敛速度较快,具有更理想的综合效益。

表 5 不同算法实现参数训练 MAE 的对比结果

训练算法	基于 DE	Fminicon	基于改进梯度法
MAE	0.1653	0.1717	0.1825
收敛时间(s)	147	7180	50

**结束语** 针对置信规则库中求解参数训练模型的问题,本文首先引入了群智能算法中的差分进化算法,并在此基础上分别提出了更合理的专家干预策略及涉及更多置信规则库参数的训练模型,进而提高了经参数训练后 BRB 系统的推理准确性。实验分析中,本文还引入了多极值函数和输油管道检漏的实例,并重点分析对比了本文方法中专家干预策略的有效性和其他现有参数训练方法的算法性能,实验结果表明本文方法是有效可行的。群智能算法和并行算法在置信规则库参数训练中相结合的应用将是我们下一步研究的重点。

参 考 文 献

[1] Yang Jian-bo, Liu Jun, Wang Jin, et al. Belief rule-base inference methodology using the evidential reasoning approach-RIMER [J]. IEEE Transactions on Systems, Man and Cybernetics, Part A: Systems and Humans, 2006, 36(2): 266-285

[2] Dempster A P. A Generalization of Bayesian Inference [J]. Journal of the Royal Statistical Society. Series B (Methodological), 1968, 30(2): 205-247

[3] Shafer G. A mathematical theory of evidence[M]. Princeton: Princeton university press, 1976

[4] Hwang C L, Yoon K. Methods for Multiple Attribute Decision Making[M] // Multiple Attribute Decision Making. Springer Berlin Heidelberg, 1981: 58-191

[5] Zadeh L A. Fuzzy sets[J]. Information and control, 1965, 8(3): 338-353

[6] Sun R. Robust reasoning: integrating rule-based and similarity-based reasoning[J]. Artificial Intelligence, 1995, 75(2): 241-295

[7] 周志杰, 杨剑波, 胡昌华. 置信规则库专家系统与复杂系统建模[M]. 长沙: 科学出版社, 2011

[8] Yang Jian-bo, Liu Jun, Xu Dong-Ling, et al. Optimization models for training belief-rule-based systems[J]. IEEE Transactions on Systems, Man and Cybernetics, Part A: Systems and Humans, 2007, 37(4): 569-585

[9] Jiang Jiang, Li Xuan, Zhou Zhi-jie, et al. Weapon system capability assessment under uncertainty based on the evidential reasoning approach[J]. Expert Systems with Applications, 2011, 38(11): 13773-13784

[10] Chang Rui, Zhang Su. An Algorithm for Training Parameters in Belief Rule-bases Based on Gradient Methods with Optimization Step Size[J]. Journal of North China Institute of Water Conservancy and Hydroelectric Power, 2011, 32(1): 154-157

[11] 王正志, 薄涛. 进化计算[M]. 长沙: 国防科技大学出版社, 2000

[12] Chang Lei-lei, Li Meng-jun, Jiang Jiang, et al. Parameter learning for the belief rule base system in the residual life probability prediction of metalized film capacitor[J]. Knowledge-Based System, 2014, 73: 69-80

[13] Wang Ying-ming, Yang Jian-bo, Xu Dong-ling, et al. The evidential reasoning approach for multiple attribute decision analysis using interval belief degrees[J]. European Journal of Operational Research, 2006, 175(1): 35-66

[14] Yang Jian-bo, Liu Jun, Xu Dong-ling, et al. Optimization models for training belief-rule-based systems[J]. IEEE Transactions on Systems, Man and Cybernetics, Part A: Systems and Humans, 2007, 37(4): 569-585

[15] Zhou Zhi-jie, Hu Chang-hua, Yang Jian-bo, et al. Online updating belief rule based system for pipeline leak detection under expert intervention [J]. Expert Systems with Applications, 2009, 36(4): 7700-7709

[16] Storn R, Price K. Differential evolution-a simple and efficient adaptive scheme for global optimization over continuous spaces [M]. Berkeley: ICSI, 1995

[17] Lampinen J. A bibliography of differential evolution algorithm [R]. Lappeenranta University of Technology, Finland, 2001

[18] Storn R, Price K. Differential evolution-a simple and efficient heuristic for global optimization over continuous spaces [J]. Journal of global optimization, 1997, 11(4): 341-359

[19] Chen Yu-wang, Yang Jian-bo, Xu Dong-ling, et al. On the inference and approximation properties of belief rule based[J]. Information Sciences, 2013, 234: 121-135

[20] Xu Dong-ling, Liu Jun, Yang Jian-bo, et al. Inference and learning methodology of belief-rule-based expert system for pipeline leak detection[J]. Expert Systems with Applications, 2007, 32(1): 103-113