

分 类 号 _____

收藏编号 _____

学校代码 10386



密级 _____

学号 _____

编号 _____

福州大学

工程硕士专业学位研究生学位论文（毕业）论文

（应用研究）

基于选择性集成学习的置信规则库推理方
法及应用研究

工 程 领 域： _____ 计算机技术

研 究 方 向： _____ 智能决策与专家系统

研 究 生 姓 名： _____

指 导 教 师、职 称： _____

所 在 学 院： _____ 数学与计算机科学学院

答辩委员会主席签名： _____

二〇一七 年 十 一 月

一 遵守学术行为规范承诺

本人已熟知并愿意自觉遵守《福州大学研究生和导师学术行为规范暂行规定》和《福州大学关于加强研究生毕业与学位论文质量管理的规定》的所有内容，承诺所提交的毕业和学位论文是终稿，不存在学术造假或学术不端行为，且论文的纸质版与电子版内容完全一致。

二 独创性声明

本人声明所提交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得福州大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。本人完全意识到本声明的法律结果由本人承担。

三 关于论文使用授权的说明

本人完全了解福州大学有关保留使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。（保密的论文在解密后应遵守此规定）

本学位论文属于（必须在以下相应方框内打“√”，否则一律按“非保密论文”处理）：

- 1、保密论文： ☐ 本学位论文属于保密，在_____年解密后适用本授权书。
2、非保密论文： ☐ 本学位论文不属于保密范围，适用本授权书。

研究生本人签名：_____

签字日期：20 年 月 日

研究生导师签名：_____

签字日期：20 年 月 日

基于选择性集成学习的置信规则库推理方法及应用研究

中文摘要

随着信息化时代的到来,人们对数据处理的需求日益旺盛,在这样的大环境下,对数据处理方法的研究成为了研究的热点。其中 Yang 等在 Dempster-Shafer 理论、决策理论及传统 IF-THEN 规则的基本框架上研究并提出了基于证据推理算法的置信规则库推理方法,该方法能有效处理带有含糊或不确定性、不完整的数据。在置信规则库中,参数的选取和置信规则库的结构直接影响着推理的精度,关于参数训练问题, Yang 等提出了参数优化的模型,并采用的 Fmincon 函数进行求解,虽然取得了一定的改进,但在精度与效率上仍存在不足;而关于置信规则库结构的研究方面,现有的研究大多是采用单一系统结构的方式进行推理预测,存在系统整体性能不稳定等问题,而部分关于多个系统集成研究方法则会随着系统数量增多而产生效率低下等问题,因此如何从多个系统中筛选出部分系统进行集成就成了一个具有研究意义的问题。为解决上述问题,本文开展了如下研究工作:

(1) 针对置信规则库中参数训练优化的问题,本文基于群智能算法中的布谷鸟搜索算法进行改进拓展。针对布谷鸟搜索算法中 Levy 飞行后期出现的搜索速度慢和精度低的问题,引入自适应扰动函数进行优化,进而提出一种新的置信规则库参数训练方法。由多极值函数拟合实验以及输油管道泄漏检测的实例,验证该算法具有更好的性能。

(2) 在置信规则库推理中,单个置信规则库在进行推理时,性能受到训练集的限制,系统泛化性能不够全面,稳定性不足,而在引入集成学习进行推理时,预测速度与存储空间又会受到影响,针对上述问题,引入选择性集成学习,选取部分置信规则库系统子集进行集成推理。最后应用于回归问题,由实验结果验证置信规则库选择性集成学习推理的可行性。

(3) 静态选择性集成方法在开展推理预测时,对于待预测的全部样本都采用一样的置信规则库系统子集进行推理,没有充分利用样本自身的特征,对于部分样本无法得到较好的预测结果。鉴于此,引入动态选择性集成方法,对于每个未知样本,寻找训练样本中类似的个体,采用对这些个体预测效果较好的置信规则库系统子集进行推理,从而提升整体的推理性能。最后采用 UCI 的分类数据集展开实验分析并与其它现有方法对比,表明本文所提方法拥有更优的推理性能。

关键词: 置信规则库; 参数学习; 布谷鸟算法; 选择性集成学习; 动态选择

Research and application of belief rule base inference method based on selective ensemble learning

Abstract

With the advent of the information age, the demand for data processing is increasing. In such a large environment, research on data processing methods has become a hot spot for research. Among them, Yang have studied and proposed the belief rule-base inference methodology using the evidence reasoning approach based on Dempster-Shafer theory, decision theory and the traditional IF-THEN rules. This method can effectively deal with ambiguity or uncertainty, uncomplete data. In the belief rule base, the selection of parameters and the structure of the belief rule base have a direct impact on the accuracy of inference. For the parameter training problem, Yang proposed a parameter optimization model and adopted the Fmincon function to solve the problem. Although some improvements have been made. However, there are still some shortcomings in the aspects of accuracy and efficiency. For the research on the structure of the belief rule base, most of the existing researches used the single system for reasoning and prediction, and some researches with the ensemble learning methods will lead to inefficiencies as the number of systems increases. However, how to select some systems from multiple systems to ensemble is a research question. In order to solve the above problems, this paper carried out the following research work:

(1) Aiming at the problem of parameter training optimization in belief rule base, this paper improves and expands the cuckoo search algorithm which is one of the swarm intelligence algorithm. Aiming at the slow search speed and low accuracy of late Levy flight in cuckoo search algorithm, the adaptive disturbance function is introduced to optimize, and then a new parameter training method of belief rule base is proposed. The multi-extremal function fitting experiment and the oil pipeline leak detection example show that the algorithm has better performance.

(2) In the belief rule base reasoning, the performance of a single belief rule base is limited by the training set, the generalization performance of the system is not comprehensive enough and the stability is not enough. When the ensemble learning was

used for reasoning, the prediction speed and memory space will be affected. In response to the above problems, selective ensemble learning is introduced and part of the belief rule base is selected for system reasoning. Finally, it is applied to the regression problem, and the experimental results verify the feasibility of the selective rule-based reasoning.

(3) When the method of static selective ensemble learning was used for reasoning, all the samples to be predicted are all based on the same set of rules of the belief rule base, which do not make full use of the characteristics of the samples and can not get better prediction for some samples result. In view of this, the dynamic selective ensemble method was introduced, for the method, it was first to find some similar individuals in the training sample for each unknown sample. And then find some belief rule base systems that have the better prediction for these individuals. Finally, the unknown sample was predicted by the ensemble of these belief rule base systems. At last, the experimental data are analyzed by UCI's classification dataset and compared with other existing methods, which shows that the method in this chapter has better reasoning performance.

Keyword: belief rule base; parameter learning; cuckoo search algorithm; selective ensemble learning; dynamic selection

目录

中文摘要	I
Abstract	II
第一章 引言	1
1.1 课题研究背景和意义.....	1
1.2 国内外研究现状.....	2
1.2.1 置信规则库推理的研究现状.....	2
1.2.2 选择性集成学习的研究现状.....	3
1.3 论文主要研究内容.....	4
1.4 论文组织结构.....	4
第二章 RIMER 方法与选择性集成学习的介绍	6
2.1 引言.....	6
2.2 置信规则库推理方法.....	6
2.2.1 BRB 的表示.....	6
2.2.2 RIMER 方法的推理机制.....	7
2.3 BRB 的参数训练方法.....	10
2.3.1 BRB 参数训练模型.....	10
2.3.2 现有参数学习方法及不足.....	12
2.4 选择性集成学习的介绍.....	12
2.4.1 选择性集成的基学习器生成过程.....	12
2.4.2 选择性集成学习的基学习器融合过程.....	13
2.5 本章结语.....	14
第三章 置信规则库参数训练的布谷鸟搜索算法	15
3.1 引言.....	15
3.2 基于布谷鸟算法的参数训练方法.....	15
3.2.1 自适应扰动的布谷鸟算法.....	15
3.2.2 新参数训练方法的算法步骤.....	17
3.3 实验分析.....	19
3.3.1 多极值函数实例.....	19
3.3.2 输油管道检漏实例.....	22
3.4 本章结语.....	25
第四章 基于 CS 的置信规则库的选择性集成学习.....	26
4.1 引言.....	26

4.2 BRB 系统的选择性集成学习.....	26
4.2.1 选择性集成学习的基本思想.....	26
4.2.2 选择性集成学习的回归问题实现.....	27
4.3 实验结果与分析.....	28
4.3.1 多极值函数分析.....	28
4.3.2 输油管道检漏.....	29
4.4 本章结语.....	32
第五章 基于动态选择性集成学习的置信规则库分类系统	33
5.1 引言.....	33
5.2 动态选择性集成学习的分类问题研究.....	33
5.2.1 动态选择性集成学习的概念.....	33
5.2.2 选择性集成学习的分类问题理论.....	34
5.3 置信规则库的动态选择性集成学习.....	36
5.3.1 置信规则库的线性建立.....	36
5.3.2 置信规则库的动态选择性集成算法步骤.....	38
5.4 实验结果与分析.....	38
5.4.1 实验数据集.....	38
5.4.2 实验结果.....	40
5.5 本章结语.....	41
结论与展望	42
参考文献	44
在学期间的研究成果以及发表的学术论文	48

第一章 引言

1.1 课题研究背景和意义

置信规则库推理(belief rule-base inference methodology using the evidence reasoning approach, RIMER)方法是在 Dempster-Shafer 理论^[1,2]、决策理论^[3]、模糊理论^[4]和 IF-THEN 规则^[5]的基本框架上研究总结并提出的,可以对模糊或缺失的数据进行推理预测^[6]。目前,该方法已经有效地应用于工程系统的安全评估^[7]、输油管道的泄漏检测^[8]和石墨成分的分析^[9]等领域。

通过对置信规则库推理过程的研究可以发现,置信规则库(belief rule base, BRB)系统中参数的选取对最终的推理精度有很大程度的影响。针对 BRB 系统的参数优化问题, Yang 等^[9]首次提出了 BRB 的参数优化模型。而后专家们在此方向上陆续开展了进一步的研究,并提出了基于梯度下降算法^[11]、基于变速粒子群算法^[12]、基于差分进化算法^[13]以及基于改进粒子群算法^[14]等的参数优化模型。虽然专家们研究并提出的这些算法以及在一定的程度上解决了部分由参数选取不合理产生的推理性能较差的问题,但到目前为止现有的这些优化方法依旧有其缺陷所在,如系统实现过于复杂、收敛效率不佳以及易早熟收敛等问题。鉴于上述的分析,为了得到具有更好的推理性能的 BRB 系统,对置信规则库参数训练方法的进一步研究具有重要的意义。

随着信息化进程的不断发展,我们的生活与信息化的联系越来越紧密,人们在各个领域的行为与信息都作为数据被收集起来,进而产生了大量的数据,比如电子交易的消费信息、用户搜索的相关数据、物流中的用户及货物信息、股票交易信息等。对于这些数据,其中具有价值的特征信息被大量杂乱无效的信息淹没。因此如何在这些数据中以较好的效率和准确性获取其中有意义的信息特征成为了一个具有研究意义的问题。在机器学习领域,强学习器难以直接构造,而性能较差的弱学习器则比较容易构造。因此, Kearns 和 Valiant^[15]首先给出了通过弱学习器构造强学习器的想法,根据这一想法,给出了集成学习(Ensemble Learning, EL)研究的可行发展方向。对于集成学习的研究一般针对两个部分,一个是针对集成学习产生多组弱学习器的方法的研究,另一个则是对于所有的弱学习器进行融合输出的方法研究。集成学习的发展历程表明,在大部分的应用场景中,采用将多个弱学习器进行集成的方法可以显著提升弱学习器的性能。由于在回归与分

类问题中集成学习表现出了优秀的预测能力,因此对于这方面的研究成为了信息时代下热门且具有价值的研究方向,研究者已经将其应用于语音识别^[16]、医疗诊断^[17]、文本信息处理^[18]等领域。

虽然将多个弱学习器进行集成可以优化最终的性能,但当弱学习器的数量开始逐步增多时,对于问题的推理效率开始降低,需要的内存空间也逐步增大。同时,弱学习器中的各个学习器的性能也存在差异,一些性能较弱的学习器可能会降低最终的集成预测效果。另外弱学习器中存在的许多相似的弱学习器导致了弱学习器之间的差异性降低,进而导致对推理结果的纠错能力下降。鉴于此,人们针对这一问题,引入了选择操作以减少弱学习器的数量。选择性集成学习^[19-21](Selective Ensemble Learning, SEL)是对所有的弱学习器进行筛选,根据特定的策略,在保持推理系统间的差异性较大的状况下,选出部分拥有良好推理能力的基学习器进行集成推理,最终通过实验分析验证选择性集成学习可以提升原始集成方法的预测性能,取得更好的推理精度与推理效率。综上所述,为得到更好的预测精度与效率,针对选择性集成学习的研究具有重要的价值。

1.2 国内外研究现状

1.2.1 置信规则库推理的研究现状

传统 BRB 系统中存在部分需要通过专家的相关知识和相关信息进行设置的参数,若参数的设置值不准确则将导致对于问题的推理结果出现推理准确率低等问题。鉴于此, Yang 等最早开始构建 BRB 系统优化模型,对 BRB 系统中的参数进行训练^[9],主体的思想是将 BRB 系统输出的推理值与实际值进行比较,从而反馈给 BRB 系统,进而进行参数的修正,最终提高 BRB 系统的推理性能,最初的训练方法使用 Fmincon 函数来进行处理;而后 Chen 等在此基础上引入前件属性候选值,扩展了原有模型的参数优化方法^[22],然而 Chen 等依旧采用 MATLAB 中的 Fmincon 函数;因此,许多研究者都开展了寻求更加有效的方法来替代 Fmincon 函数的研究工作,如 Chang 等^[23]引入了梯度下降和二分求解的思想,对原始方法在推理精度上得到了改进;而后研究者开始将群智能算法与置信规则库进行结合并展开探索, Wang 等^[13]提出专家干预下差分进化(DE)算法的 BRB 参数优化方法、Su 等^[12]提出基于变速粒子群(PSO)算法的 BRB 参数优化方法,得到了优于 FMINCON 函数的性能。Chang 等^[24]对原始的特征进行筛选从而减少了属性的维度,进而简化了置信规则库的规则; Zhou 等^[8]结合期望极大估计算法,以在线参数训练的模式进行学习; Alberto 等^[25]在此框架上进行改进并得出动态规则激活方法,改进了原有方法的稳定性; Chang 等^[26]针对数据属性个数

较大时产生的“组合爆炸”问题，以线性组合的方法生成较少的规则进行推理；在此基础上叶等^[27]在分类问题的 BRB 求解模型中，设定规则数等同于类别数，将 BRB 最终的结果评价等级与问题中的分类类别一一对应，对个体匹配度公式加以改进，从而进一步避免了规则的“零激活”问题。Wang^[28]等从优化 BRB 系统结构的角度出发，结合粗糙集进行属性约减的研究；Liu^[29]等针对 BRB 系统在分类问题上的应用，引入 BRB 数据驱动的思想将其与 DE 算法相结合得到了较好的结果；Fang 等^[30]对匹配问题展开进一步研究，提出了 BRB 系统的多属性双边匹配算法；同时 Fang 等^[31]还针对纹理图像分类问题，结合主成分分析法提出了纹理图像的 BRB 推理方法；Wu 等^[32]针对单个 BRB 系统推理稳定性不足的问题，引入集成学习的思想，提出基于集成学习的 BRB 系统推理方法。

1.2.2 选择性集成学习的研究现状

对于传统的集成学习方法，当基学习器的数量不断增大之后，整体系统的预测效率将随之急剧下降。针对这一问题，Zhou 等^[33-34]最早给出了选择性集成的思想，从所有基学习器中选取部分对待预测样本进行最终的预测推理，从而提升了整体系统的推理效率。对于选择性集成学习选择方法的研究主要包含有静态选择(static selection)和动态选择(dynamic selection)。静态选择是在对于基学习器进行选择之后，得到的基学习器子集固定不变，对于所有的个体都采用这个基学习器子集进行推理。如 Lazarevic 等^[35]采用聚类算法的思想先将基学习器分组，进而在保证多样性的基础上选取基学习器；Martinez-Munoz 等^[36]结合 Boosting 的思想，以排序的方式对基学习器进行选取；Rokach 等^[37]提出了基于 CAP (Collective-Agreement-based Pruning) 的选择方法，即对于每个基学习器子集，根据其中每个基学习器的性能及冗余性对子集排序，进而选取总体较好的基学习器子集；Zhang 等^[38]在 Boosting 算法的基础上，对原有方法加以改进并对 Double-Bagging 生成的基学习器排序筛选，进而得到更好的系统性能；Margineantu 等^[39]结合 Kappa-Error 图对 AdaBoost 集成学习器进行分类；Tamon 等^[40]在此基础上提出了启发式方法来进一步优化；Caruana 等^[41]从基学习器种类的角度出发，结合异质的分类方法通过数据训练出不同的基学习器，进而加大基学习器集的多样性，从而得到了较好的效果；Ting 等^[42]结合交叉确认的方式选取综合能力最好的基学习器对问题进行求解；上述的方法对于待预测的个体都采用一样的基学习器推理求解。但是，存在部分基学习器对于整体的预测效果不佳，但对于有某一特征的个体却能够进行精准的预测，因此引入了动态选择性集成学习。

动态选择性集成的思想是针对不同种类的待预测个体，根据其特征不同选取的基学习器进行推理求解。Soares 等^[43]通过基学习器对数据推理正确率以及基学

习器间的差异性进行衡量选择,提出了不同的方法:利用 K-means 聚类计算推理正确率和多样性从而对未知样本利用各聚类中心的基学习器进行集成的方法;另一种是利用 K-NN 找到与未知样本接近的 K 个已知样本,根据正确率与多样性进行选择基学习器子集进行预测的方法; Ko 等^[44]提出基于 K-nearest-oracles(KNORA)的动态集成算法; Dos 等^[45]提出 DOCS(Dynamic Overproduce and Choose Strategy)的动态集成算法; Wang 等^[46]引入蚁群算法加快多学习器的筛选速度,改进了传统的集成学习方法; Xiao 等^[47]采用对噪声免疫性较强的启发式数据挖掘策略,进而提出了集成分类器的动态选择算法。

1.3 论文主要研究内容

本文针对 BRB 系统的参数优化和选择性集成学习的相关内容开展研究,具体内容包括如下三个方面:

第一,为了进一步提升 BRB 系统的效能,需要对 BRB 系统的参数进行优化。通过研究现有的参数优化方法,分析现有方法的优缺点,在此基础上提出一种基于群智能算法的参数优化方法,结合布谷鸟搜索算法,引入自适应因子进行改进,最终使 BRB 系统拥有更好的性能。

第二,研究 BRB 系统的选择性集成学习方法在回归问题上的实现与优化。集成学习将所有训练得到基学习器都参与到预测中,对比单个 BRB 系统取得了更好的性能,但随着基学习机的数量逐渐增大,预测的速度会明显下降。因此结合 Bagging 算法的思想生成不同的训练集,进而生成不同的 BRB 系统,从中选取部分 BRB 系统子集,最终应用于回归问题,对其进行推理预测。

第三,研究 BRB 系统的动态选择性集成学习方法在分类问题上的实现与优化。针对 BRB 系统中出现的“组合爆炸”问题,运用线性的方式生成置信规则库,同时引入动态选择性集成学习的思想对第二部分的方法进行改进,以此优化并提高 BRB 系统选择性集成学习的推理能力。

1.4 论文组织结构

本文的主体内容共有五个章节,其结构描述如下:

第一章是论文的引言,主要内容是 BRB 系统的推理过程和参数训练方法以及选择性集成学习的研究背景、现状及意义,最后从总体上概述了研究内容及组织结构。

第二章对杨剑波教授提出的 RIMER 方法以及 BRB 参数训练的方法进行介绍,并且还介绍选择性集成学习的基学习器生成过程和融合过程,为之后的 BRB 系统参数优化和选择性集成学习相关的研究奠定了基础。

第三章主要是针对现有 BRB 系统参数训练的不足之处,提出基于布谷鸟算法的 BRB 参数训练方法。在现有置信规则库参数训练方法的基础上,结合布谷鸟算法对新的参数训练模型进行改进,提升了置信规则库系统推理的效率和准确性。最后通过与其他现有的 BRB 参数优化方法在多极值函数拟合和输油管道泄漏检测问题中的表现加以对比分析,检验了本章方法具有一定的实用性。

第四章针对 BRB 系统对于回归问题的推理,提出了 BRB 回归系统的选择性集成学习。在前一章的研究中发现,置信规则库推理存在一定的不稳定性,在训练的过程中,若训练集存在局限性,就将产生参数优化效果不佳的问题。因此引入集成学习中的 Bagging 算法生成具有差异性的训练集,增加 BRB 系统的多样性,同时为避免过多的系统降低训练效率和推理精度,结合选择性集成学习的思想,选取 BRB 系统子集对问题加以求解,以此提高置信规则库的推理性能。在实验分析中针对回归问题,将选择性集成学习的 BRB 系统与单个 BRB 系统以及现有的其他方法进行对比,通过采用与上一章相同的实验内容进行对比,从而验证选择性集成学习对原方法的改进。

第五章针对 BRB 系统对分类问题的推理预测,结合动态选择的思路,提出了 BRB 系统的动态选择性集成学习。在前一章的方法中,我们采用了静态选择性集成的 BRB 系统,对所有样本采用固定的 BRB 系统子集,忽略了单个未知样本自身的特征,为进一步提高置信规则库推理性能,合理分析单个未知样本的特征,引入了动态选择性集成学习算法,选取训练集中与当前待预测样本的特征相似的样本,找出对这些样本训练效果更优的基学习器子集,对当前样本进行集成预测。在实验部分,采用 UCI 分类数据,将动态选择性集成学习的 BRB 算法与现有其他方法进行对比分析,从而验证本章方法的有效性。

最后一部分为结论与展望,通过结论对本文的研究工作与创新点加以总结,并在指出现有研究存在的可提升空间,进而对之后的研究方向给出规划。

第二章 RIMER 方法与选择性集成学习的介绍

2.1 引言

Yang 等提出的 BRB 推理方法是在 D-S 理论^[1,2]、决策理论^[3]、模糊理论^[4]和 IF-THEN 规则^[5]的基本框架上研究总结出来的,可以对模糊或缺失的数据进行推理预测^[6]。该方法主要包括规则的表达和推理机制的描述,即对知识的表示以及对知识的推理。知识的表达具体表现为对于规则库的描述,其中参数的取值是对于知识表达影响较大的因素。而知识的推理则是通过对激活权重的计算进而根据 ER 算法对规则进行合成,进而从已知知识推导出未知的信息。BRB 系统的推理过程是透明的,因此易于理解认知。

在推理预测的问题中,不同的 BRB 系统有着不同的特性,单一的 BRB 系统存在不稳定性,在对大量的数据进行推理预测时容易产生误差。因此,将多个不同的 BRB 系统统一进行集成推理预测,从而提高推理预测结果的准确性。同时为了避免 BRB 系统过多导致的推理效率降低,以及个别较差的 BRB 系统影响整体的推理性能,引入选择性集成学习,进而提高整体的推理预测能力。

本章将介绍 BRB 系统的相关理论、参数训练以及选择性集成学习的主要过程,其中包括 BRB 系统的规则表示和推理方法以及选择性集成学习的基学习器生成过程与融合过程,为 BRB 系统的参数训练以及基于选择性集成的 BRB 推理提供理论依据。

2.2 置信规则库推理方法

在机器学习领域使用规则的形式来描述数据的相关信息是一种常见的方法。在 BRB 系统的推理方法中,通过 BRB 的规则化方式来描述数据,进而通过证据理论算法进行预测。

2.2.1 BRB 的表示

基于 IF-THEN 规则的系统通常由下式表示:

$$R = \langle U, A, D, F \rangle \quad \text{公式(2-1)}$$

式中 $U = \{U_i; i=1, \dots, T\}$ 表示前件属性集合; $A = \{A_1, A_2, \dots, A_T\}$ 对应所有前件属性的取值, $A_i = \{A_{i,j}; j=1, \dots, J_i = |A_i|\}$ 指代前件属性参考值组成的集合;

$D = \{D_n; n=1, \dots, N\}$ 表示规则结果的评价等级; F 是前件属性与评价结果的关系。

BRB 系统中的置信规则在 IF-THEN 规则的基础上增加了分布式框架, 并为前件属性和规则都设置相应的权值。下式给出第 k 条规则的表示:

$$\begin{aligned} R_k : & \text{If } A_1^k \wedge A_2^k \wedge \dots \wedge A_{T_k}^k, \\ & \text{Then } \{(D_1, \bar{\beta}_{1,k}), (D_2, \bar{\beta}_{2,k}), \dots, (D_N, \bar{\beta}_{N,k})\} \\ & \text{With a rule weight } \theta_k \text{ and attribute weight } \delta_{1,k}, \delta_{2,k}, \dots, \delta_{T_k,k} \end{aligned} \quad \text{公式 (2-2)}$$

式中“ \wedge ”是逻辑与符号, 第 k 条置信规则中第 i 个前件属性参考值为 $A_i^k (i=1, 2, \dots, T_k; k=1, 2, \dots, L)$, 第 k 条规则中前件属性的总数为 T_k , L 表示规则的总数; $D_j (j=1, 2, \dots, N)$ 表示规则的不同评价等级, 总数是 N ; $\bar{\beta}_{j,k} (j=1, 2, \dots, N, k=1, 2, \dots, L)$ 指代第 k 条置信规则中的第 j 个评价类型 D_j 的置信度; 当 $\sum_{j=1}^N \bar{\beta}_{j,k} = 1$ 时, 即第 k 条规则的信息是完备的, 否则存在不确定性。此外, $\theta_k (k=1, 2, \dots, L)$ 表示第 k 条规则的规则权重; $\delta_{i,k} (k=1, 2, \dots, L, i=1, 2, \dots, T_k)$ 是前件属性权重。

2.2.2 RIMER 方法的推理机制

RIMER 方法的具体过程由三步组成, 先是计算规则的激活权重, 然后修正数据中不确定部分的置信度, 最后应用 ER 的合成激活规则对推理结果加以合成。

2.2.2.1 激活权重的计算

激活权重要算出前件属性在所有候选值上的匹配度, 如果 BRB 的输入 $x_i (i=1, 2, \dots, M)$ 以数值表示, 则通过 x_i 和前件属性的候选值 $A_i^k (i=1, 2, \dots, T_k)$, 结合变换公式^[48]可以算出第 k 条规则的第 i 个输入与候选值 A_i^k 的个体匹配度 α_i^j 为

$$\begin{cases} \alpha_i^j = \frac{A_i^{k+1} - x_i}{A_i^{k+1} - A_i^k}, & A_i^k \leq x_i \leq A_i^{k+1} \text{ and } j = k \\ \alpha_i^{j+1} = 1 - \alpha_i^k, & A_i^k \leq x_i \leq A_i^{k+1} \text{ and } j = k \\ \alpha_i^s = 0, & s \neq \begin{cases} k \\ k+1 \end{cases} \end{cases} \quad \text{公式(2-3)}$$

对于第 k 条规则, 激活权重求解方法为:

$$\omega_k = \frac{\theta_k \prod_{i=1}^{T_k} (\alpha_i^k)^{\bar{\delta}_{k,i}}}{\sum_{l=1}^L \theta_l \prod_{i=1}^{T_k} (\alpha_i^l)^{\bar{\delta}_{l,i}}}, \bar{\delta}_{k,i} = \frac{\delta_{k,i}}{\max_{i=1, \dots, T_k} \{\delta_{k,i}\}} \quad \text{公式(2-4)}$$

式中, $\omega_k \in [0,1]$, $k=1,2,\dots,L$; α_i^k 为第 k 条规则的第 i 个输入值与候选值 A_i^k 进行对比后的匹配度。

2.2.2.2 修正置信度

若输入数据不具备完备性时,则必须将第 k 条规则的第 i 个评价类型 D_i 的置信度 $\bar{\beta}_{i,k}$ 调整到合理的范围内,具体的公式为:

$$\beta_{i,k} = \bar{\beta}_{i,k} \frac{\sum_{t=1}^{T_k} \left(\tau(t,k) \sum_{j=1}^{|A_t|} \alpha_{t,j} \right)}{\sum_{t=1}^{T_k} \tau(t,k)} \quad \text{公式(2-5)}$$

$$\tau(t,k) = \begin{cases} 1, & A_t \in R_k (t=1, \dots, T_k) \\ 0, & \text{otherwise} \end{cases}$$

式中 $|A_t|$ 为前件属性的数量, R_k 为确定的评价类型,当 $\beta_{i,k} = \bar{\beta}_{i,k}$ 时,表明输入数据具有完整性。

2.2.2.3 合成激活规则

根据 ER 算法,可以通过每条规则的置信度与属性权重算出属性的可信度^{[49][50]},具体表示为:

$$m_{n,i} = \omega_i \beta_{n,i} \quad \text{公式(2-6)}$$

$$m_{H,i} = 1 - \omega_i \sum_{n=1}^N \beta_{n,i} = \bar{m}_{H,i} + \tilde{m}_{H,i} \quad \text{公式(2-7)}$$

$$\tilde{m}_{H,i} = \omega_i (1 - \sum_{n=1}^N \beta_{n,i}) \quad \text{公式(2-8)}$$

$$\bar{m}_{H,i} = 1 - \omega_i \quad \text{公式(2-9)}$$

上式中 $n=1, \dots, N$, $i=1, \dots, L$ 。

求得可信度之后,运用 ER 算法的解析式^[51]就能合成全部的属性,具体表示

如下：

$$C_n = k \left[\prod_{j=1}^L (m_{n,j} + \bar{m}_{H,j} + \tilde{m}_{H,j}) - \prod_{j=1}^L (\bar{m}_{H,j} + \tilde{m}_{H,j}) \right] \quad \text{公式(2-10)}$$

$$\tilde{C}_H = k \left[\prod_{j=1}^L (\bar{m}_{H,j} + \tilde{m}_{H,j}) - \prod_{j=1}^L \bar{m}_{H,j} \right] \quad \text{公式(2-11)}$$

$$\bar{C}_H = k \prod_{j=1}^L \bar{m}_{H,j} \quad \text{公式(2-12)}$$

$$k^{-1} = \sum_{n=1}^N \prod_{j=1}^L (m_{n,j} + \bar{m}_{H,j} + \tilde{m}_{H,j}) - (N-1) \prod_{j=1}^L (\bar{m}_{H,j} + \tilde{m}_{H,j}) \quad \text{公式(2-13)}$$

然后，能算出新合成属性的结果评价类型的置信度，其具体公式为：

$$\beta_n = \frac{C_n}{1 - \bar{C}_H} (n=1, \dots, N) \quad \text{公式(2-14)}$$

$$\beta_H = \frac{\tilde{C}_H}{1 - \bar{C}_H} \quad \text{公式(2-15)}$$

式中 β_n 和 β_H 是分别是评价类型 D_n 和缺失信息的置信度。

在通常情况下，输出的结果需要转化为单一数值，因此，可以通过算出 BRB 系统的期望效用值求得具体数值。如果等级效用值为 $u = \{u_1, u_2, \dots, u_N\}$ ，则 BRB 系统的效用值表达如下：

$$\begin{aligned} \mu_{\min} &= (\beta_1 + \beta_D) \mu_1 + \sum_{j=2}^N \beta_j \mu_j \\ \mu_{\max} &= (\beta_N + \beta_D) \mu_N + \sum_{j=1}^{N-1} \beta_j \mu_j \\ \mu_{\text{avg}} &= \frac{\mu_{\min} + \mu_{\max}}{2} \end{aligned} \quad \text{公式(2-16)}$$

2.3 BRB 的参数训练方法

BRB 系统中参数的选取直接影响着预测的精度，BRB 系统中的参数首先由专家给出，但专家对数据的理解存在一定的局限性，进而导致系统的推理精度不够高。因此，研究者开始研究 BRB 的参数优化方法，进而让 BRB 系统拥有更强的实用性。

2.3.1 BRB 参数训练模型

在研究 BRB 系统的参数优化方法的过程中，Yang 等^[9]最先给出 BRB 系统的参数优化模型，通过对系统预测值与实际值的误差分析对系统参数进行重复调整，使得 BRB 系统拥有不断改进的能力，从而得到提升系统的推理性能。而后研究者在此方向上逐步研究了基于 FMINCON 函数、梯度下降^[11]、变速粒子群^[12]、差分进化^[13]和改进粒子群^[14]等的参数优化模型。其中，Yang 等提出的 BRB 参数学习的模型如图 2-1 所示。

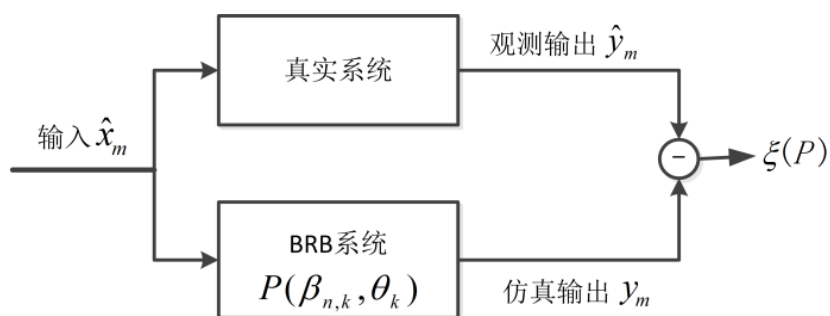


图 2-1 BRB 参数训练模型

在图 2-1 中， P 表示需要进行训练的参数向量，其中 $\beta_{n,k}$ 表示规则权重， θ_k 表示属性权重， \hat{x}_m 是数据的输入； \hat{y}_m 是输入数据对应的真实值， y_m 是 BRB 系统的进行计算后得出的预测值， $\xi(P)$ 表示 \hat{y}_m 与 y_m 的差值，即真实值与预测值的差值。该参数模型的最终目标是令 $\xi(P)$ 的值尽可能小，该模型的最终目标函数以及包含的约束条件表示如下：

$$\begin{aligned} & \min \{ \xi(P) \} \\ & s.t. \ A(P) = 0, B(P) \geq 0 \end{aligned} \quad \text{公式(2-17)}$$

其中具体的约束条件为：

(1)BRB 中每一条规则对应的结果评价类型的置信度一般取值为[0,1]，第 k 条规则中的第 n 个结果评价类型对应置信度应符合下式限制范围：

$$0 \leq \beta_{n,k} \leq 1, n=1,2,\dots,N; k=1,2,\dots,L \quad \text{公式(2-18)}$$

(2) 假设第 k 条规则的输入具有完备性，置信度总和为 1。

$$\sum_{n=1}^N \beta_{n,k} = 1, k=1,2,\dots,L \quad \text{公式(2-19)}$$

(3) 第 k 条规则的权重 θ_k 进行归一化操作后， θ_k 值应该取 0 到 1 的范围内。

$$0 \leq \theta_k \leq 1, k=1,2,\dots,L \quad \text{公式(2-20)}$$

若问题中包含 M 组输入、输出值 $(\hat{x}_m, \hat{y}_m)(m=1,2,\dots,M)$ ，由公式(2-17)和公式(2-18)所述，实际的输出值如下：

$$\hat{y}_m = \sum_{j=1}^N \mu(D_j) \hat{\beta}_j(m) \quad \text{公式(2-21)}$$

同理，BRB 系统的仿真输出可表示为：

$$y_m = \sum_{j=1}^N \mu(D_j) \beta_j(m) \quad \text{公式(2-22)}$$

则 BRB 参数优化模型对应的目标函数是：

$$\begin{aligned} \min_P \xi_j(P) \\ \text{s.t. } (2-19) \sim (2-21) \end{aligned} \quad \text{公式(2-23)}$$

为了衡量置信规则库的预测值和真实值的差距，常用的方法是采用均方差进行计算，由此可得目标函数为：

$$\xi(P) = \frac{1}{M} \sum_{m=1}^M (y_m - \hat{y}_m)^2 \quad \text{公式(2-24)}$$

2.3.2 现有参数学习方法及不足

Yang 等^[9]最早开始构建 BRB 系统训练模型，对其中的参数进行训练优化，其主体思想是将 BRB 系统输出的推理值与实际值进行比较，从而反馈给 BRB 系统，进而进行参数的修正，最终提高 BRB 系统的推理性能，最初的训练方法使用 Fmincon 函数来进行处理；而后 Chen 等在此基础上引入前件属性候选值，扩展了原有训练模型的参数训练方法^[22]，然而 Chen 等依旧采用 MATLAB 中的 Fmincon 函数，若需要进行推理预测的问题较为复杂，参数较多，则该函数将表现出效率与精度都较为低下的性能；因此，许多研究者都对于寻找更加有效的方法来替代 Fmincon 函数，如，Chang 等^[23]引入了梯度下降和二分求解，虽然对于原始方法在推理精度上得到了改进，但是只改进了 BRB 系统中的部分参数，并且大大增加了推理和实现的复杂度，且推理效率仍然较低；因此研究者开始将群智能算法与置信规则库进行结合的探索，Wang 等^[13]提出专家干预下 DE 算法的 BRB 参数优化方法、Su 等^[12]提出基于 PSO 算法的 BRB 参数优化方法，得到了优于 FMINCON 函数的性能。Zhou 等^[8]结合期望极大估计算法，以在线参数训练的模式进行学习，但该方法中设计的分布模型需要人为进行设置，容易产生缺陷，且对于许多实际问题无法进行应用；Alberto 等^[25]在此框架上进行改进并得出动态规则激活方法，改进了原有方法的稳定性；Chang 等^[26]针对数据属性个数较大时产生的“组合爆炸”问题，以线性组合的方法生成较少的规则进行推理，但规则数量的确定决定了系统的推理性能，这一特性限制了该方法泛化能力；Wang^[28]等从优化 BRB 系统结构的角度出发，结合粗糙集进行属性约减的研究；Liu^[29]等针对 BRB 系统在分类问题上的应用，引入 BRB 数据驱动的思想将其与 DE 算法相结合，虽然该方法得到了较好的推理精度，但当问题较为复杂时，规则的生成效率较低；Fang^[30]等对匹配问题展开进一步研究，提出了 BRB 系统的多属性双边匹配算法；同时 Fang^[31]还针对纹理图像分类问题，结合主成分分析法提出了纹理图像的 BRB 推理方法，这两种虽然取得较好的结果，但对于应用的问题类型存在局限性；Wu^[32]等针对单个 BRB 系统推理稳定性不足的问题，引入集成学习的思想，提出基于集成学习的 BRB 系统推理方法，但当集成的 BRB 系统较多时系统的效率将大幅下降，同时精度也难以提升。

2.4 选择性集成学习的介绍

2.4.1 选择性集成的基学习器生成过程

选择性集成学习是通过在众多基学习器中选取部分对最终的问题进行推理的方法。因此在算法中如何能够生成具有多样性的基学习器集就是该方法中重要

的一部分。其中 Bagging 算法是常用的基学习器生成方法，该方法是采用对原始的数据集进行有放回地抽取部分数据生成具有差异性的训练子集，对 BRB 系统通过这些具有差异性的训练集进行训练，从而得到拥有一定多样性的 BRB 系统集。令给定的数据集包含 n 个样本，对于每一个新训练集，都是从原始数据中随机抽取样本，每次抽取后都将样本放回，重复 n 次操作，从而使得每个训练集都包含 n 个样本。采用这种方法会导致在一些训练集中，原始数据中的样本可能重复出现或不出现。其中每个样本存在当前训练集中的概率是 $1/n$ ，则不存在的概率是 $(1-1/n)$ ，因此某个样本在所有训练集中都不存在的概率是 $(1-1/n)^n$ 。若数据量 n 较大且不断趋近于无穷大时，每个样本不出现的概率为 $e^{-1} = 0.368$ ，训练集中样本出现的比例占原始集合的 63.2%。

2.4.2 选择性集成学习的基学习器融合过程

在选择性集成学习的融合过程中，共包含选择与集成两个主要步骤，其中选择方式分为静态选择和动态选择。静态选择是在对于基学习器进行选择之后，得到的基学习器子集固定不变，对于所有的个体都采用这个基学习器子集进行推理。静态选择算法可以按照如下进行划分：（1）排序法：采用特定的衡量标准将基学习器排序，然后将其中评估后性能较优的基学习器依次选出用于问题的推理预测。

（2）聚类法：对于引入聚类的思想对原始的基学习器集合进行分类，之后用得到的聚类结果按照推理性能与差异性选取其中部分子集进行最终的推理预测。（3）优化法：采用向量的形式对各个基学习器赋予贡献值，结合优化的方法计算出包含贡献值的向量，然后采用合适的算法选取基学习器子集进行推理预测。（4）其他方法：例如 prodromidis 等提出的通过基学习器集成结果生成决策树，而后对决策树进行剪枝，剪枝后结果不包含于决策树中的基学习器将被移除；再比如 Partalas 等结合强化学习的思想提出的新的方法。上述的方法对于全部待预测的个体都采用一样的子集对个体的类别求解。但是，存在部分基学习器对于整体的预测效果不佳，但对于有某一特征的个体却能够进行精准的预测，因此引入了动态选择性集成学习。动态选择性集成的思想是针对不同种类的待预测个体，根据其特征不同选取的基学习器进行推理求解。常见的方法包括：（1）对于每个未知样本，根据其对应的特征，采用均方差等衡量其与已知样本的差异值，找出部分与其最接近的已知样本，选取对这些样本推理性能最好的基学习器子集对当前未知样本进行推理；（2）对已知样本，根据其本身的特征进行聚类操作，而后对于每一个未知样本，寻找与其最相近的聚类，将部分聚类中心的样本取出，选取对这些样本推理准确度最高的基学习器子集对当前的未知样本加以推理集成。

对于融合过程中的集成过程，可分为回归与分类两个问题进行研究。对于回

归问题，常用的方法有：（1）采用取平均法，即将全部的基学习器推理数值相加取平均；（2）采用加权平均法，即对全部的基学习器分别设定权值，进而对最终的推理数值加权取平均；（3）将所有基学习器的预测值进行聚类操作，其中最大类的聚类中心为最终的输出。对于分类问题，常用的方法有：（1）多数投票法，即预测结果中出现最多的类作为最终的输出类；（2）加权投票法，根据基学习器的性能分别设置权值，而后将加权后票数最多的类视为系统对未知样本的预测结果。

2.5 本章结语

本章主要介绍了 BRB 推理方法、BRB 系统的参数训练方法以及选择性集成学习的相关内容。主要包括了置信规则库的表示、置信规则库的推理机制、参数训练的优化模型以及选择性集成学习中的基学习器生成算法和基学习器融合算法。本章通过介绍 BRB 系统与 SEL 的相关内容，为接下来的内容提供基础。

第三章 置信规则库参数训练的布谷鸟搜索算法

3.1 引言

通过第二章对 BRB 推理方法和 BRB 的参数训练模型的相关知识的分析,可以发现 BRB 系统的推理性能受到参数取值的影响。因此本章将针对参数取值的问题详细介绍置信规则库参数训练的布谷鸟搜索算法。

最初 BRB 系统的参数由人为根据已知的条件与历史数据进行设定,而后,随着 BRB 系统的推理方法应用的问题越来越多样,此时人为设定参数的方法已经难以实现。因此, Yang 等^[9]提出了 BRB 系统的参数优化模型,其主要内容是通过将实际值与 BRB 系统输出值进行对比,对 BRB 系统的参数进行反馈,从而展开自学习使得实际值与 BRB 系统输出值的差值尽可能小的过程。在此基础上后续的研究者分别引入了群智能算法以及机器学习方法等。这些方法在一定程度上改进了原有的参数设置问题,同时使得推理性能也得到了相应的提升,然而现有的方法依旧存在问题,还有着继续提升的空间,如系统实现过于复杂、收敛效率不佳以及易早熟收敛等。

综上所述,本文结合布谷鸟搜索(Cuckoo Search, CS)算法^[52],提出了基于自适应扰动 CS 算法的 BRB 参数训练方法。该算法实际上是运用 CS 算法求解优化模型,但标准 CS 算法鲁棒性不佳,求解的精度存在不足。为此本文引入自适应扰动策略,增加算法中每一代个体之间的差异性,并控制迭代过程中个体的活动范围,从而优化种群的进化过程并得到更优的精度。在实验部分,本文采用多极值函数的拟合效果,与其他现有方法进行比较,从而验证自适应扰动布谷鸟搜索算法能够取得更好的推理精度与推理速度;最后将该算法应用于输油管道检漏的实例中,并与其他现有的方法进行比较,进一步验证本文改进的方法对实际问题具有良好的适用性。

3.2 基于布谷鸟算法的参数训练方法

3.2.1 自适应扰动的布谷鸟算法

CS 算法是由剑桥大学 Yang 和 S.Deb 受到布谷鸟育雏与寻巢习性启发而提出的一种群智能算法^[52]。布谷鸟在育雏时具有寄生育雏(Brood Parasitism)的习性,而在移动中则具有莱维飞行(Levy flight)的特征,该算法通过对这两种行为的模拟来有效地求解最优化问题^[53]。

标准的 CS 算法采用飞行与遗弃并寻找新巢这两种方式对个体进行更新：
通过 Levy flight 对当前个体进行更新,具体公式为：

$$x_i^{(t+1)} = x_i^{(t)} + \alpha \oplus L(\lambda) \quad \text{公式(3-1)}$$

式中， $x_i^{(t+1)}$ 表示第 t+1 代中第 i 个个体； α 为飞行距离的量，以此限制随机搜索的范围大小； \oplus 为点对点乘法； $L(\lambda)$ 为 Levy flight 随机数，服从 Levy 分布,如下式所示：

$$L(\lambda) \sim u t^{-\lambda}, 1 < \lambda \leq 3 \quad \text{公式(3-2)}$$

在 Levy flight 随机取值后，可将当前个体中最优的个体作为参考值进行移动，最终的移动公式如下所示：

$$x_i^{(t+1)} = x_i^{(t)} + \alpha_0 \frac{\Phi \times \mu}{|\nu|^{1/\beta}} (x_i^{(t)} - x_{\text{best}}^{(t)}) \quad \text{公式(3-3)}$$

式中： $x_{\text{best}}^{(t)}$ 为第 t 代中最优个体； μ, ν 为标准正态分布； α_0 为常数，用于限制个体移动的范围； β 为常数，范围为[1,2]之间。 Φ 取值如下：

$$\Phi = \left\{ \frac{\Gamma(1+\beta) \times \sin\left(\frac{\pi \times \beta}{2}\right)}{\Gamma\left[\left(\frac{1+\beta}{2}\right) \times \beta \times 2^{\frac{\beta-1}{2}}\right]} \right\}^{1/\beta} \quad \text{公式(3-4)}$$

式中： Γ 为标准 Gamma 函数。

(2) 对于适应值较差的鸟巢，由察觉概率 Pa 判断该鸟巢是否需要被遗弃并寻找新位置。新位置的生成方式如下：

$$x_i^{(t+1)} = x_i^{(t)} + \gamma \oplus (x_j^{(t)} - x_k^{(t)}) \quad \text{公式(3-5)}$$

式中： $\gamma \in [0,1]$ ，服从均匀分布； $x_i^{(t)}$ ， $x_j^{(t)}$ ， $x_k^{(t)}$ 分别为第 t 代中的 3 个随机个体。

(3) 为增加种群的多样性，本文引入一种新的更新方法，即自适应扰动。

$$x_i^{(t+1)} = x_i^{(t)} + \frac{a}{Gen} \oplus \varepsilon \quad \text{公式(3-6)}$$

式中： ε 为与 $x_i^{(t)}$ 同阶的高斯矩阵； \oplus 表示点对点乘法； a 为常数，根据实际问题进行调整； Gen 表示当前更新代数。通过上式可以发现，随着更新代数的逐步增加，扰动的范围会随之减小。因此在算法前期自适应扰动会在当前鸟巢附近较远的地方寻找更优解，而到了搜索后期，自适应扰动会进行更细微的移动，从而得到更加精确的解。

3.2.2 新参数训练方法的算法步骤

本章提出的基于 CS 算法的参数训练算法具体步骤如下：

步骤 1 初始化鸟巢。给定种群大小与发现概率，并在已知的限定条件内随机选取鸟巢的初始位置。

步骤 2 计算鸟巢的适应值。根据实际问题设置目标函数，并以各个鸟巢位置代入目标函数后产生的误差值作为衡量标准，计算出各个鸟巢的适应值。

步骤 3 依次从当前各个鸟巢出发进行 Levy flight，由公式(3-3)计算出飞行后的新位置。之后对鸟巢各个维度上超出限定条件的数值进行修正，防止出现鸟巢位置超出搜索空间的情况。

步骤 4 根据迁移概率 Pa 对鸟巢进行迁移，由公式(3-5)计算出鸟巢的新位置。

步骤 5 由公式(3-6)对当前鸟巢进行自适应扰动，进而寻找更优的位置。

步骤 6 如果当前更新次数未达到初始给定的次数，则返回步骤 3；否则将当前最优解保留并设置为 BRB 系统的参数，算法结束。

流程图如下：

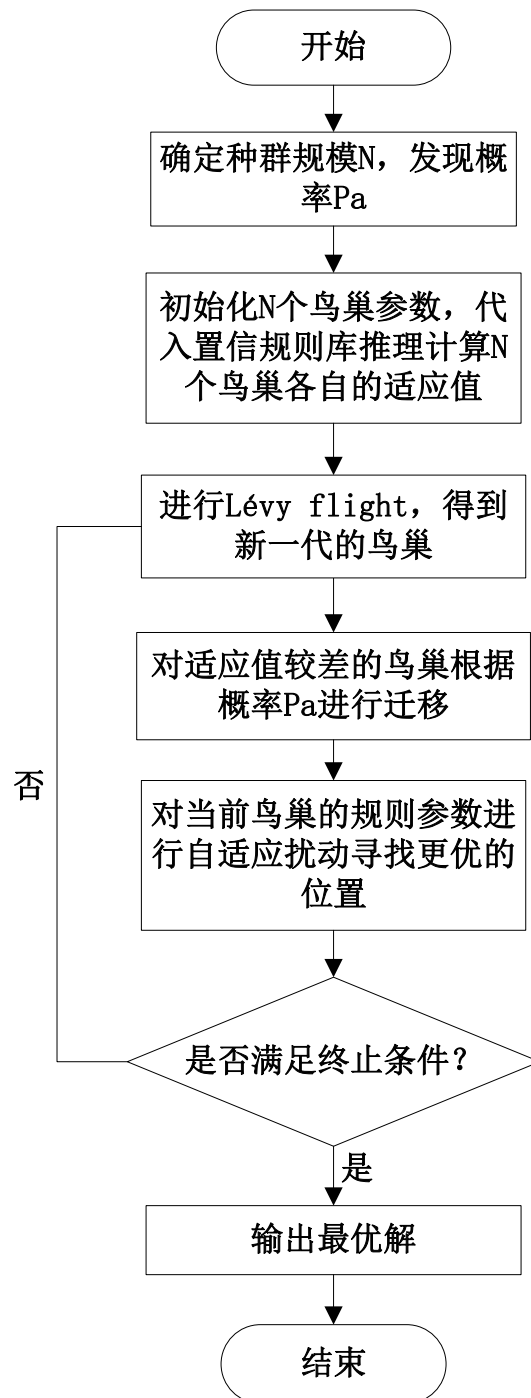


图 3-1 CS 算法参数训练流程图

3.3 实验分析

本章的实验由多极值函数拟合与输油管道检漏构成，实验由 C++编写实现，通过 MATALAB 画图进行分析。实验环境为：Intel(R) Core(TM) i5-4570 @ 3.20GHz CPU、8GB 内存，Windows 7 操作系统。

3.3.1 多极值函数实例

首先以多极值函数的拟合实验验证基于布谷鸟搜索算法的参数训练方法的可靠性，多极值函数的具体式子如下：

$$g(x) = e^{-(x-2)^2} + 0.5e^{-(x+2)^2} \quad \text{公式(3-7)}$$

式中， $g(x)$ 在 $x=0$ 附近以及在 $x=-2, x=2$ 处分别局部或者整体的极值。根据这些特殊位置的点，置信规则的结果集可以按照如下进行表示：

$$\{D_1, D_2, D_3, D_4, D_5\} = \{-0.5, 0, 0.5, 1, 1.5\}$$

由文献[54]可知对于该函数，若以 5 条规则对 BRB 进行初始化参数设置，其的取值为表 3-1 中的内容：

表 3-1 初始置信规则库

规则	规则权重	候选值	$g(x)$	结果集 $\{D_1, D_2, D_3, D_4, D_5\} = \{-0.5, 0, 0.5, 1, 1.5\}$
1	1	-5	0.0001	$\{D_1, D_2, D_3, D_4, D_5\} = \{0, 0.9999, 0.0001, 0, 0\}$
2	1	-2	0.5000	$\{D_1, D_2, D_3, D_4, D_5\} = \{0, 0, 1, 0, 0\}$
3	1	0	0.0275	$\{D_1, D_2, D_3, D_4, D_5\} = \{0, 0.9725, 0.0275, 0, 0\}$
4	1	2	1.0000	$\{D_1, D_2, D_3, D_4, D_5\} = \{0, 0, 0, 1, 0\}$
5	1	5	0.0001	$\{D_1, D_2, D_3, D_4, D_5\} = \{0, 0.9998, 0.0002, 0, 0\}$

未经参数学习的 BRB 系统拟合函数效果如图 3-2：

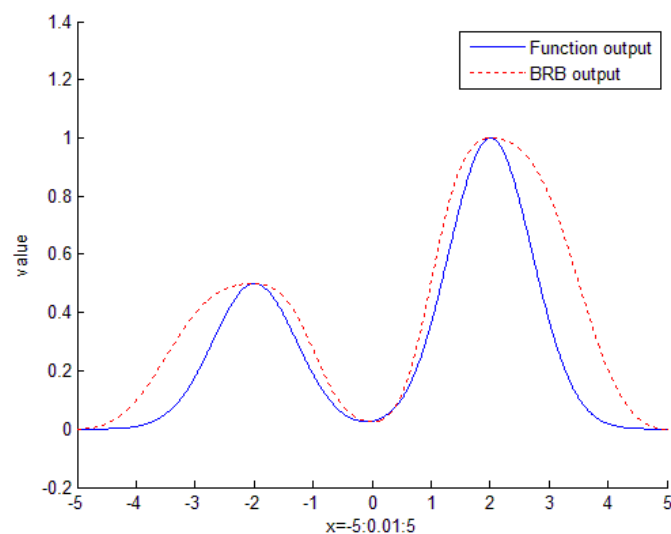


图 3-2 初始 BRB 系统的拟合效果

采用 MATLAB 中的 FMINCON 函数^[55]进行优化后的 BRB 系统拟合结果如图 3-3:

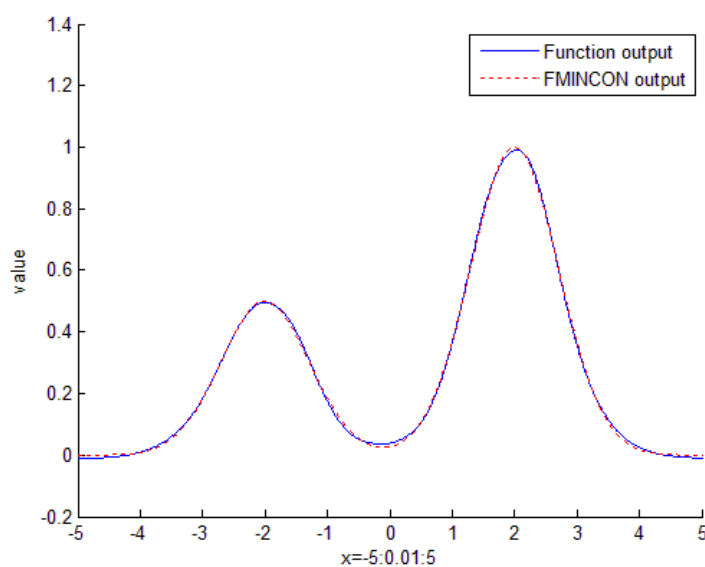


图 3-3 FMINCON 算法参数训练后拟合的效果

进行参数优化时, 选取该函数上 1000 个以相同间隔分布的点为训练集, 设置种群的规模为 25, 将均方误差 MSE 视为目标函数。

表 3-2 训练后的置信规则库

规则	规则权重	候选值	$g(x)$	结果集 $\{D1, D2, D3, D4, D5\} = \{-0.5, -0.1955, 0.3258, 1.0347, 1.5\}$
1	0.92399	-5	0.0001	$\{D1, D2, D3, D4, D5\} = \{0.4383, 0.324, 0.0329, 0.0941, 0.1106\}$
2	0.35918	-2.03488	0.4994	$\{D1, D2, D3, D4, D5\} = \{0.1717, 0.2206, 0.2282, 0.0186, 0.3608\}$
3	0.51370	-0.07494	0.0258	$\{D1, D2, D3, D4, D5\} = \{0.4168, 0.2248, 0.2186, 0.0001, 0.1397\}$
4	0.36575	2.06587	0.9957	$\{D1, D2, D3, D4, D5\} = \{0.0341, 0.2379, 0.0244, 0.0003, 0.7034\}$
5	0.95557	5	0.0001	$\{D1, D2, D3, D4, D5\} = \{0.2198, 0.4979, 0.1324, 0.1496, 0.0003\}$

采用基于 CS 算法优化的 BRB 系统对该函数的拟合结果为图 3-4:




图 3-4 基于 CS 算法的 BRB 参数训练结果

对比图 3-2、3-3、3-4 中的函数拟合结果发现, 未训练的 BRB 系统无法对函数进行有效的拟合, 由此可知进行参数的训练过程是必要的。而由图 3-4 可知结合布谷鸟搜索算法可以更加有效地避免陷入局部最优, 且进行过参数优化的 BRB 系统拥有更好的性能, 可以得到更好的拟合结果。

对比传统 FMINCON 方法的 BRB 系统进行拟合的多极值函数与本文提出算法的均方误差(MES)差异如下图 3-5 所示:




图 3-5 Fmincon 与 CS BRB 以及标准 CS BRB 拟合结果的 MES 对比

图 3-5 表明,基于自适应扰动布谷鸟搜索算法的 BRB 系统相比基于 Fmincon 函数的 BRB 系统以及标准的布谷鸟搜索算法的 BRB 系统取得了更好的性能。

在表 3-3 中将本章方法与 FMINCON 方法^[55]、Chen 的方法^[22]及 Wang 的方法^[13]分别从预测准确性及运行时间加以对比,分别采用均方误差(Mean Square Error, MSE)和时间进行衡量。

表 3-3 BRB 系统推理性能的比较

BRB 系统类型	MSE	运行时间/秒
Fminicon	5.16×10^{-5}	496.71
Chen-BRB	6.3228×10^{-5}	—
Wang-BRB	3.9284×10^{-5}	386.63
CS-BRB	3.3322×10^{-5}	357

表 3-3 表明本章提出的基于 CS 的 BRB 推理方法能够得到比 Fmincon 函数、Wang 的方法以及 Chen 的方法推理更加准确的结果。而且 Fmincon 函数依赖于 Matlab 可移植性差,推理效率低下,可见本文方法更为有效。

3.3.2 输油管道检漏实例

为了验证基于布谷鸟搜索算法的 BRB 参数训练方法在面对真实的预测问题时是否具有有效性,引入了输油管道检查泄漏的案例^[6]开展实验进行测试。本实验的实验数据来自于过去英国的一条输油管道在实际发生泄漏时,收集到的具体数据。

在分析该实例时可以考虑到,当液体在管道内时,若流入量大于流出量,则管内的压力值应当随着管内的液体总量增多而增大,减小而减小,若不满足这一特性,则表明当前的管道内存在着液体泄漏现象。在这一分析过程中,可以发现,通过对某处管道内的平均压力(PD)以及流入流出的差值(FD)的分析能够了解当前管道位置的具体泄漏情况。

对于初始 BRB 的构建,以输出流量差(Flow Difference, FD)和管道内平均压力(Pressure Difference, PD)作为前件属性, FD 有 8 个参考值、PD 有 7 个参考值。并选取泄漏量大小(Leak Size, LS)作为输出,共分为 5 个评价等级。前件属性流量差值 FD、管道平均压力 PD 以及输出集 LS 在经过处理后,可以得到以下的参考值:

$$FD = \{-10, -5, -3, -1, 0, 1, 2, 3\} \quad \text{公式(3-8)}$$

$$PD = \{-0.042, -0.025, -0.01, 0, 0.01, 0.025, 0.042\} \quad \text{公式(3-9)}$$

$$LS = \{0, 2, 4, 6, 8\} \quad \text{公式(3-10)}$$

由 FD 和 PD 可得到 56 条置信库规则参数,从而组成 BRB 系统^[53],实验时,以 2007 组数据作为测试集,对于训练集则是采用随机选取其中 500 组数据的方式进行生成,以平均绝对误差 MAE 作为目标函数。未训练 BRB 系统对整个输油管道泄漏情况的拟合结果为图 3-6。




图 3-6 初始 BRB 系统拟合结果

根据图 3-6 可以了解到未训练的 BRB 系统由于参数设置存在偏差的问题, 导致对输油管道存在的泄漏进行分析时与实际情况存在较大的差异, 因此有必要对 BRB 的参数进行训练。

训练后的 BRB 系统的推理结果如图 3-7 所示:




图 3-7 训练后 BRB 系统输出和训练数据

由图 3-6 与图 3-7 进行对比可以很显然地了解到在 BRB 系统的参数进行过基于 CS 的参数训练方法优化取值后, BRB 系统能够对管道各处的泄漏情况作出较为准确的预测结果, 相比于未训练的 BRB 系统, 得到了更好的拟合结果。

由于上图的比较只能体现出本章提出的方法相对初始 BRB 系统在推理精度上的优越性, 为了更全面地对该方法进行评估, 实验中将引入现有的几种较为优秀的参数训练方法, 同时在推理精度与推理时间上进行比较, 由平均绝对误差 MAE 表示推理的性能, 运行时间表示推理的时间效率, 最终的比较数据为表 4-4。

表 3-4 BRB 系统推理性能的比较

BRB 系统类型	MAE	运行时间/秒
初始 BRB	0.914578	-
Fminicon	0.1717	7180
Xu-BRB ^[56]	0.171969	13449.060742
PSO-BRB ^[12]	0.197631	283.425000
Chen-BRB ^[53]	0.170341	21705.962351
VPSO-BRB ^[12]	0.166478	290.150000
专家干预下的 DE-BRB ^[13]	0.1653	147

CS-BRB	0.1611	143
--------	--------	-----

根据表 3-4 中本章算法与其他现有的几种较好的 BRB 推理方法的比较可以得出，本章所提的基于 CS 的 BRB 推理方法在推理准确度以及推理速度两个维度上都得到了优于其他方法的效果，由此可验证，本章所提的方法在真实问题中进行应用时也具有实用性和有效性。

3.4 本章结语

本章内容由 BRB 推理方法中参数优化的想法引出，为了能够得到较好的参数的方法，以 Yang 等提出的参数优化模型为基础，在现有的关于结合群智能算法的研究中得到启发，在标准 CS 算法的基础上引入自适应因子，进而结合 BRB 推理方法。采用抽象的函数拟合实验以及真实的输油管道检漏两个截然不同的实验通过与近年来较为优秀的 BRB 推理方法进行对比，较为全面地检验了本章方法具有适用性。

第四章 基于 CS 的置信规则库的选择性集成学习

4.1 引言

在前一章的内容中, 本文改进了传统 BRB 系统的参数训练模型, 结合群智能算法中的布谷鸟搜索算法对训练模型进行改进, 在回归问题中得到了更好的推理精度与推理效率。在考虑该模型的进一步改进方法时, 可以发现该模型仅由单个 BRB 系统构成, 在对于同一个问题的不同样本进行推理时, 推理性能存在不稳定性, 可能由训练集的不同或者测试集的不同导致推理性能差异较大。这一特性在实际问题中进行应用时, 令人难以接受, 因为一次的失败就足以导致巨大的损失。因此从提高稳定性的角度出发, 考虑引入多个 BRB 系统进行集成学习。多个 BRB 系统的推理加强了整体推理结果的稳定性, 但是随着进行集成的 BRB 系统的数量增多, 系统推理的效率开始下降, 同时部分性能较差的 BRB 系统也降低了整体集成的推理性能。为解决这一问题, 本章进行了进一步的研究, 结果选择性集成学习的方法, 筛选出部分 BRB 系统对问题进行推理, 在提高系统稳定性的基础上保证了系统的推理效率。

综上所述, 本章在第三章内容的研究基础上加以改进, 提出了基于 CS 的 BRB 系统的选择性集成学习, 采用集成学习中常用的 Bagging 算法从初始数据中不断随机选取固定数量的数据生成多个具有差异性的训练集, 并结合第三章的布谷鸟算法进行参数训练从而生成不同的 BRB 系统, 从而生成具有差异度的 BRB 系统。在 BRB 系统的融合阶段, 将 BRB 系统对实验推理的误差作为衡量 BRB 系统优劣程度的参考值, 进而根据每个 BRB 系统对应的参考值选取其中较为优秀的 BRB 系统, 对于每个选取的 BRB 系统赋予相应的权重参与最终的集成推理, 对回归问题进行求解。

4.2 BRB 系统的选择性集成学习

4.2.1 选择性集成学习的基本思想

在现有的集成学习研究中, 选择性集成是其中兼顾了推理精度与推理效率的一种较为优秀的方法。SEL 的核心理念是根据某种特定的衡量标准从众多的基学习器中选取一部分对问题进行集成预测。其中每一个基学习器可以看做是对于特定问题的某一种解法, 因此选择性集成实际上是一种在解决问题时较为普遍的思想

法。基本思想如图 4-1 所示。

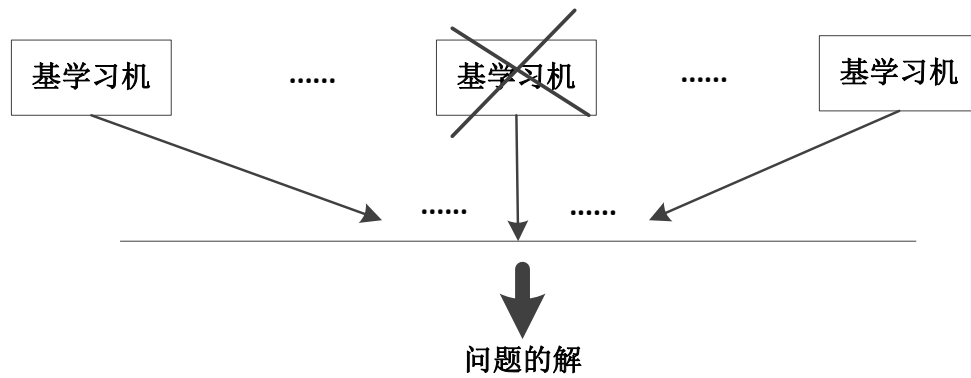


图 4-1 SEL 的整体思想

4.2.2 选择性集成学习的回归问题实现

本章的内容主要针对回归问题，关于分类的讨论将在下一章进行。在回归问题中，在 SEL 的基学习器生成阶段，采用 Bagging 算法的思想生成不同的训练集，通过基于 CS 的 BRB 系统的参数优化方法得到各自不同的 BRB 系统。在得到多个 BRB 系统后，在 SEL 的融合阶段，先采用 BRB 系统的推理误差进行划分优劣程度，进而选取其中较为优秀的 BRB 系统。对于选取出的 BRB 系统赋予每个系统与优劣程度呈正比的权重，以加权求平均的方式对多个学习机的结果进行集成。

算法 4-1: BRB 系统的选择性集成学习步骤如下:

输入: 原始训练集 S , 测试集 D , 未训练的 BRB, 生成 BRB 系统的总数 T , 训练算法 CS, 最终选择的 BRB 数量 M

输出: 集成预测结果

- ① *for* $i=1,2,\dots,T$
- ② $S_{(i)} = \text{bootstrap sample from } S$
- ③ *Call* CS
- ④ *return* $BRB_{(i)}$
- ⑤ *end*
- ⑥ 获取测试集 D
- ⑦ 计算 $BRB_{(i)}(i=1,2,\dots,T)$ 对于 D 的预测输出 $Result_{(i)}$
- ⑧ 根据 $Result_{(i)}(i=1,2,\dots,T)$ 对所有 BRB 系统进行排序
- ⑨ 在 T 个 BRB 系统中根据优劣程度选取 M 个 BRB 系统
- ⑩ 对最终选取的 M 个 BRB 系统的推理值加权求平均，求得的结果作为推理结果进行输出

具体流程如图 4-2 所示：

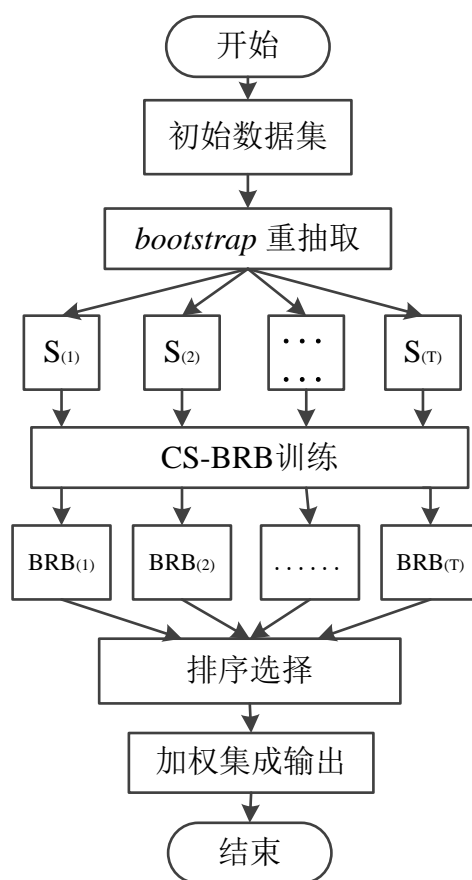


图 4-2 SEL 的算法流程图

4.3 实验结果与分析

为了验证 SEL 与 BRB 推理方法结合对推理性能的优化，采用的回归实验为与上一章相同的多极值函数拟合和输油管道检漏实验，进而与现有的其他方法加以对比，从而验证本章算法的有效性。

实验环境为：Intel(R) Core(TM) i5-4570 @ 3.20GHz CPU、8GB 内存，Windows 7 操作系统。实验由 C++编写实现，通过 MATALAB 画图进行分析。

4.3.1 多极值函数分析

函数拟合实验是常见的用于验证 BRB 系统推理性能的方法，本实验采用与上一章 3.3.1 相同的多极值函数实验，以此与上一章及其他现有的方法进行对比，从而更好地验证基于 CS 的 BRB 推理方法的选择性集成学习具有更好的性能，该函数具体如下：

$$g(x) = e^{(x-2)^2} + 0.5e^{(x+2)^2}, \quad 5 \leq x \leq 5 \quad \text{公式(4-1)}$$

对于 BRB 规则的生成采用与上一章 3.3.1 相同的方法。对于选择性集成学习的 BRB 系统生成阶段,将 2008 组数据作为原始数据采用 Bagging 算法进行有放回的随机抽取,训练集的大小为 500,测试集即 2008 组原始数据集,最终通过生成 25 个训练集分别对未训练的 BRB 系统进行训练,从而得到 25 个参数不同的 BRB 系统。进行参数优化时,选取该函数上 1000 个以相同间隔分布的点为训练集,设置种群的规模为 25,将均方误差 RMSE 视为目标函数。对于 25 个 BRB 系统以均方根误差衡量其与真实输出的误差,进而划分优劣程度并进行排序,最终选取其中最优的 5 个 BRB 系统,根据其优劣程度赋予其权重值,最终对测试集以 BRB 系统的输出值加权取平均进行推理。

在表 4-1 中将本章方法与 FMINCON 方法^[55]、Wang 的差分进化方法^[13]、Chang 的梯度方法的单个 BRB 系统^[46]及 Wu 的 BRB 集成学习方法^[30]进行比较,分别采用均方根误差(root-mean-square error, RMSE)和 PCC 对各自的推理性能进行衡量。

表 4-1 本章方法与其他方法的对比

训练算法	RMSE	PCC
MATLAB 中 FMINCON	0.00869	0.99956
Wang 的差分进化算法	0.02363	0.99675
Chang 的梯度法	0.01325	0.99915
Wu 的 BRB 的集成学习	0.00891	0.99954
本章的 BRB 选择性集成学习	0.00620	0.99977

表 4-1 表明本章提出的基于 CS 的 BRB 推理的 SEL 方法能够得到比 Fmincon 函数、Wang 的方法以及 Chang 的方法等单个 BRB 系统更好的推理性能。而且对于 Wu 的 BRB 系统集成学习也得到了更优的结果,这是因为在融合过程中选择性集成方法移除了性能较差的 BRB 系统,并且本章所提的方法较 Wu 的 BRB 集成学习方法的复杂度更低。综上所述,基于 CS 的 BRB 推理的选择性集成学习方法相较于现有的其他方法具有更好的性能,表明了其有效性。

4.3.2 输油管道检漏

实验背景与上一章的实验一致,初始 BRB 系统的构建与上一章中 3.3.2 节的内容相同。由 FD 和 PD 可得到 56 条置信库规则参数,从而组成 BRB 系统,实

验时，以 2007 组数据作为测试集，并随机抽取 500 组原始数据用于构成训练集，以平均绝对误差 MAE 为目标函数。

未训练 BRB 系统的拟合效果为图 4-3。




图 4-3 初始 BRB 系统拟合结果

4 采用 MATLAB 中 FMINCON 函数的 BRB 参数训练方法的拟合效果为图 4-




图 4-4 采用 MATLAB 中 FMINCON 的 BRB 参数优化方法的拟合效果

采用基于 CS 的 BRB 回归系统的 SEL 方法进行拟合的结果为图 4-5




图 4-5 基于 CS 的 BRB 系统的选择性集成学习的拟合结果

根据图 4-3、4-4 和 4-5 可以得到，相对于为训练的 BRB 系统以及采用 FMINCON 函数优化的 BRB 系统，本章采用的基于 CS 的 BRB 系统的选择性集成学习方法能够在稳定性提升的基础上，通过多个 BRB 系统的共同学习推理出更准确的结果，同时也兼顾了整体的运行效率。

表 4-2 本章方法与其他 BRB 推理方法的对比

训练算法	MSE	PCC
MATLAB 中 FMINCON	0.40724	0.96628
粒子群算法 ^[12]	0.44330	0.96335
加速梯度求法 ^[11]	0.44551	0.96341
BRB 系统的集成学习 ^[30]	0.41487	0.96557
BRB 系统的选择性集成学习	0.36941	0.96828

从表 4-2 中采用均方误差 MSE 对各个算法的推理精度进行衡量，实验结果表明 BRB 系统的 SEL 方法由于多个系统的综合推理得到了优于单个系统的结果，同时由于剔除了性能较差的 BRB 系统使得其性能最终也优于 BRB 的集成学习方法。皮尔森相关系数 PCC 在本实验中被用于衡量 BRB 系统的推理输出与真实输出的相关系数，本章提出的方法求得的 PCC 优于其他 BRB 系统，表明其

预测值与真实值具有更强的相关性，即对于真实系统输出的动态变化更为敏感，在进行推理时能够具有更好的推理性能。

4.4 本章结语

本章针对单个 BRB 系统存在的不稳定性以及集成多个系统时随着基学习器数量增多，导致预测的效率与内存开销急剧增加的问题，提出了基于 CS 的 BRB 推理的选择性集成学习方法。在 BRB 系统生成阶段，采用 Bagging 算法对原始数据集进行抽取，抽取出不同的训练集用于训练出不同的 BRB 系统。在 BRB 系统的融合阶段，根据各个 BRB 系统的误差衡量其优劣程度，从中选取较好的 BRB 系统以加权求平均的方式，输出最终的推理结果。在实验分析中，通过与传统的 BRB 推理方法以及结合集成学习的 BRB 推理方法进行对比，验证了基于 CS 的 BRB 推理的选择性集成学习方法的有效性。

第五章 基于动态选择性集成学习的置信规则库分类系统

5.1 引言

选择性集成算法的性能不仅与训练数据相关,还与待测试的未知样本的特征相关。根据对未知样本的处理方法可以将 SEL 算法进行分类,并得到两大类不同的方法:静态选择和动态选择。在前一章的内容中,文章提出的基于 CS 的 BRB 推理的 SEL 方法,采用了静态选择的方法,静态选择方法对未知的所有样本都采用相同的 BRB 系统集,在对 BRB 系统进行选择后,参与测试集推理预测的 BRB 系统集不再发生变化。由于部分 BRB 系统可能对于整体的预测性能不够优秀,而对于具有某些特征的待预测样本能够给出较准确的推理结果,若是单纯采用静态选择的方法,在选取 BRB 系统时容易将此类 BRB 系统排除,从而降低对于部分具有特定特征的样本分类结果,无法针对未知样本的特征给出更加有效的推理。

因此,本章结合动态选择性集成学习的思想,根据未知样本的特征,找出已知的训练集中与该样本相似的样本集,在 BRB 系统集中选取对相似样本集推理效果最佳的 BRB 系统子集,将该 BRB 系统子集对该样本进行集成推理,以此进一步优化 BRB 推理方法的预测精度。通过 Bagging 算法的数据重抽取技术选取不同的训练集,进而构造出拥有一定差异性的 BRB 系统集。在融合阶段,通过加权求平均的方法融合这些 BRB 系统的预测结果以得到更好的推理性能。实验采用 UCI 分类数据集,通过与其他现有方法的实验对比进一步验证本章算法的适用性。

5.2 动态选择性集成学习的分类问题研究

5.2.1 动态选择性集成学习的概念

动态选择性集成学习是基于研究者对选择性集成学习集成阶段中对于样本特征的考虑而得出的,希望将待预测样本的特征加以利用,用于提升 SEL 的预测精度。由此改变了最初的选择性集成学习中用于集成的基学习器不变的特性,针对不同的样本动态选取参与集成的基学习器。因此该方法的思考主要是集中在求解如何对包含不同特征的样本选取更加合适的基学习器子集。常用的策略是按

照一定的标准衡量待预测样本与已知样本之间的差异性,通过选取相似样本的集合,进一步选取对相似样本集的预测准确度较高的基学习器子集,参与最后的预测集成。

5.2.2 选择性集成学习的分类问题理论

求解问题一般可分为回归问题与分类问题,第三章与第四章的内容最终都是针对回归问题进行思考验证,因此本章内容展开对分类问题的思考,主要内容是研究在分类问题中 BRB 推理的 SEL 应当如何实现。鉴于此,对于选择性集成学习在分类问题中的应用,下述的说明可以作为其具有有效性的理论依据。

对于 N 个 BRB 系统 f_1, \dots, f_n , 在分类问题中 BRB 系统的集成结果通常由多数投票或加权投票的结果进行确认,其目标函数为 $f: R^m \rightarrow \Omega$ 。为使分析过程更加清晰,首先将 Ω 作为只包含两种类别的集合进行讨论,在此基础上,之后将进行多分类问题的探讨。对于二分类问题,其目标函数为 $f: R^m \rightarrow \{-1, +1\}$ 。

首先,定义问题的数据集 D 包含 m 个样本, $D = [d_1, d_2, \dots, d_m]^T$ 指代所有样本对应的实际类, d_j 指代数据集中的第 j 个样本对应的实际类。对于 BRB 系统对于样本的推理预测结果采用 $f_i = [f_{i1}, f_{i2}, \dots, f_{im}]^T$ 表示,式中的 f_{ij} 代表第 i 个 BRB 系统对于第 j 个样本的推理分类结果。其中 d_j 和 f_{ij} 的取值分别为 $d_j \in \{-1, +1\} (j = 1, 2, \dots, m)$ 和 $f_{ij} \in \{-1, +1\} (i = 1, 2, \dots, N; j = 1, 2, \dots, m)$ 。由 d_j 和 f_{ij} 的取值可知,对于 BRB 系统的推理结果,其中第 i 个 BRB 系统对第 j 个样本进行推理预测时,若预测类别与实际类别相同则有 $f_{ij}d_j = +1$; 不同则有 $f_{ij}d_j = -1$ 。根据这一特征,可以计算第 i 个 BRB 系统对数据集 D 中 m 个样本的整体误差如下:

$$E_i = \frac{1}{m} \sum_{j=1}^m \text{Error}(f_{ij}d_j) \quad \text{公式(5-1)}$$

式中的误差函数 $\text{Error}(x)$ 具体表示如下:

$$\text{Error}(x) = \begin{cases} 1 & \text{if } x = -1 \\ 0.5 & \text{if } x = 0 \\ 0 & \text{if } x = +1 \end{cases} \quad \text{公式(5-2)}$$

令全部 BRB 系统对于第 j 个样本的整体预测评价结果的和为 sum_j , 则对于所有样本的预测结果的和向量为 $\text{Sum} = [\text{sum}_1, \text{sum}_2, \dots, \text{sum}_m]^T$, sum_j 的公式表示如下:

$$sum_j = \sum_{i=1}^N f_{ij} \quad \text{公式(5-3)}$$

根据上式可知，所有 BRB 系统对于第 j 个样本的最终预测结果为：

$$\hat{f}_j = Sgn(sum_j) \quad \text{公式(5-4)}$$

函数 $Sgn(x)$ 为：

$$Sgn(x) = \begin{cases} +1 & \text{if } x > 0 \\ 0 & \text{if } x = 0 \\ -1 & \text{if } x < 0 \end{cases} \quad \text{公式(5-5)}$$

由此可知，对于第 j 个样本的预测结果的取值为 $\hat{f}_j \in \{-1, 0, +1\} (j=1, 2, \dots, m)$ ，根据最终 BRB 系统集的推理结果之和，如果预测的结果与实际值相同，则 $\hat{f}_j d_j = +1$ ；如果预测结果与实际值不符，则 $\hat{f}_j d_j = -1$ ；如果最终的集成结果为平局，则 $\hat{f}_j d_j = 0$ 。综上所述，BRB 系统的最终的集成误差公式如下：

$$\hat{E} = \frac{1}{m} \sum_{j=1}^m Error(\hat{f}_j d_j) \quad \text{公式(5-6)}$$

如果其中第 k 个 BRB 系统不进行最终的集成推理，那么移除后的 BRB 系统的集成对于第 j 个样本的推理结果如下：

$$\hat{f}_j' = Sgn(sum_j - f_{kj}) \quad \text{公式(5-7)}$$

进而可得出移除某个 BRB 系统后的泛化误差如下：

$$\hat{E}' = \frac{1}{m} \sum_{j=1}^m Error(\hat{f}_j' d_j) \quad \text{公式(5-8)}$$

若 $\hat{E} - \hat{E}' \geq 0$ ，则由式(5-4)、(5-6)、(5-7)及(5-8)得：

$$\sum_{j=1}^m \{Error(Sgn(sum_j) d_j) - Error(Sgn(sum_j - f_{kj}) d_j)\} \geq 0 \quad \text{公式(5-9)}$$

若式(5-9)成立，则表明在移除第 k 个 BRB 系统后最终的集成推理准确性得

到了进一步的提高, 若 $|sum_j| > 1$, 则无论被移除的第 k 个 BRB 系统的推理结果为-1 或+1, 都无法改变最终所有 BRB 系统共同得出的对于第 j 个样本的推理结果, 鉴于此, 下文只对 $|sum_j| \leq 1$ 的情形进行进一步分析。对于函数 $Error(x)$ 和 $Sgn(x)$ 当 x, y 的取值分别为 $x \in \{-1, 0, +1\}$ 、 $y \in \{-1, +1\}$ 时有下式:

$$Error(Sgn(x)) = Error(Sgn(x - y)) = -\frac{1}{2} Sgn(x + y) \quad \text{公式(5-10)}$$

由于 $|sum_j| \leq 1$, 则结合式(5-9)与公式(5-10)能够求得被移除的 BRB 系统 f_k 的限制条件如下:

$$\sum_{\substack{j=1 \\ j \in \{|sum_j| \leq 1\}}}^m Sgn((sum_j + f_{kj})d_j) \leq 0 \quad \text{公式(5-11)}$$

由于 $|sum_j| \leq 1$, 则代入可知上式成立。

最终, 通过对理论的分析可以得知, 对于初始生成的 BRB 系统集, 若从中选取部分 BRB 系统用于最终的推理预测, 则最终的推理性能能够在所有 BRB 系统都参与集成的集散得到进一步提升, 从而获得更好的推理结果。

5.3 置信规则库的动态选择性集成学习

5.3.1 置信规则库的线性建立

对于置信规则的生成, 传统的方法是采用对于所有可能的候选值进行组合的方式进行生成, 由此可知, 这样的组合方法为指数级别的, 随着属性的数量以及属性候选值数量的增多, 规则数将产生“组合爆炸”的问题, 使得规则的生成变得令人难以接受。假设对于某个分类问题的求解, 若该问题中的每个样本有 20 个属性, 每个属性又对应 4 个候选值, 则在生成置信规则时, 将产生 $4^{20} = 1099511627776$ 条规则, 这样的规则库不仅无法进行保存, 同时更加无法进行正常的 BRB 推理, 为了解决 BRB 推理方法在多属性问题上的求解问题, Chang^[25]等从对规则库采用线性构建的方法进而提出了 BRBCS, 具体思想为图 5-1:

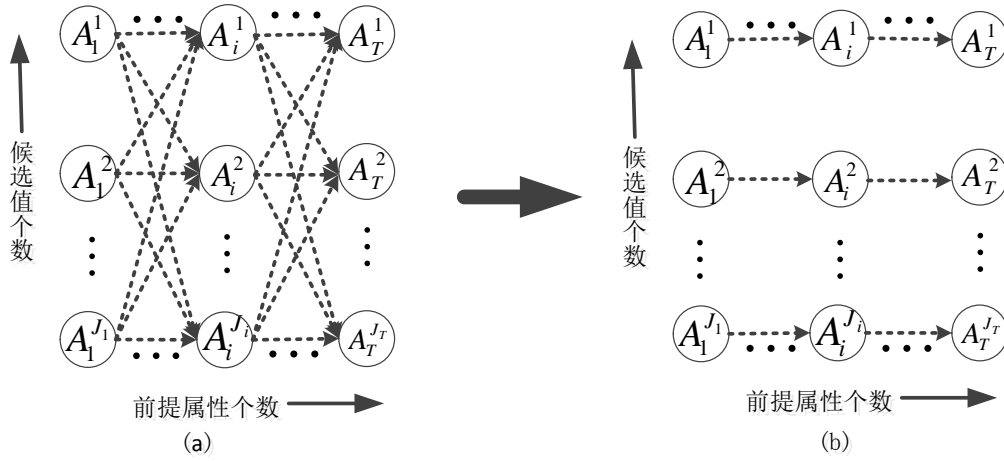


图 5-1(a)遍历组合规则, (b)线性组合规则

Chang 等关于线性组合生成置信规则的研究虽然还存在一些问题,如无法有效平衡 BRB 系统的推理性能以及规则库规则数量的关系,但这一想法为后来的研究者提供了新的思路。而后, Ye 等^[25]在这一研究方向上做了进一步的研究,提出根据分类问题中的样本类别数量设定选取的规则数量,通过理论及实验进行分析,最终将 BRB 规则结果的评价等级对应于样本类别。同时针对 BRB 推理过程中存在的“零激活”问题,对个体匹配度的运算方式加以调整,将原始公式中的计算方法改为以输入值与参考值的距离倒数进行归一化,则修改后,在第 k 条规则中第 i 个个体的匹配度公式如下:

$$\alpha_i^k = \frac{1/|A_i^k - x_i|}{\sum_{j=1}^L 1/|A_j^k - x_j|} \quad \text{公式(5-12)}$$

式中, L 指代规则总数, x_i 指代输入个体 x 的第 i 个属性, A_i^k 指代第 k 条规则中第 i 个前件属性对应的参考值。

对于第 k 条规则, 相应的激活权重求解方法为:

$$\omega_k = \frac{\theta_k \sum_{i=1}^T \alpha_i^k}{\sum_{l=1}^L (\theta_k \sum_{i=1}^T \alpha_i^l)} \quad \text{公式(5-13)}$$

5.3.2 置信规则库的动态选择性集成算法步骤

置信规则库的 SEL 的具体步骤如下：

步骤 1 在原始训练集中，采用 bagging 随机重抽取技术生成不同的训练集，通过不同的训练集分别对初始 BRB 系统进行训练，从而生成不同的 BRB 系统。

步骤 2 将所有的 BRB 系统应用于完整的原始训练集，从而计算出每个 BRB 系统的推理性能。

步骤 3 对于需要求解的所有未知样本，通过将训练集中的样本与当前样本的特征差异进行对比运算，找出与其最为相似的 K 个样本。

步骤 4 针对这 K 个样本，在所有 BRB 系统中，根据已知的推理结果，选择推理精度最高的 M 个 BRB 系统。

步骤 5 对选择的 M 个 BRB 系统加权求和，进而对当前未知样本的类别进行集成推理。

步骤 6 如果当前仍然有未知样本，则回到步骤 3；否则输出对所有未知样本的预测结果，算法结束。

5.4 实验结果与分析

为了进一步验证基于动态 SEL 的置信规则库推理方法在分类问题中的可行性，本节将选取 UCI 中的分类数据集进行实验，并将其与其他方法加以对比分析，从而验证本章方法的适用性。

实验环境为：Intel(R) Core(TM) i5-4570 @ 3.20GHz CPU、8GB 内存，Windows 7 操作系统，实验由 C++编写实现。

5.4.1 实验数据集

本实验的测试数据集源于 UCI 数据库中的 3 个分类问题，具体如表 5-1 所示。

表 5-1 UCI 数据集信息

数据集	属性个数	类别数	数据个数
Cancer	30	2	569
Iris	4	3	150
Glass	9	7	214

对于 BRB 系统初始的构建通常采用专家设置参数值的方法，而对于多种多

样的分类问题难以对其中每一个问题都找到相对较优的初始参数,因此本章算法将对原始的 BRB 参数应用随机的思想加以生成。假定在某个分类问题中共有 N_D 个样本,所有样本共有 C 种不同的类别,每个样本包含 τ 个前件属性,采用上述的线性组合方式生成置信规则时,每个前件属性都拥有 C 个参考值,最终的评价等级划分与样本的类别数相等, BRB 系统的规则总数也为 C 。

以随机生成的方式设置 BRB 系统初始参数值的过程如下:

(1) 将第 k 条规则的权重 θ_k 的初始值进行随机赋值:

$$\theta_k = rand^k() \quad (k = 1, 2, \dots, C) \quad \text{公式(5-14)}$$

(2) 同样地,随机生成第 i 个前件属性的权重 δ_i 如下:

$$\delta_i = rand^i() \quad (i = 1, 2, \dots, \tau) \quad \text{公式(5-15)}$$

(3) 对于第 k 条规则中第 i 个前件属性的参考值 $A_{i,k}$, 首先找出所有样本对应的最小值与最大值作为取值的上下边界,进而根据规则数与类别数进行划分,具体值设置如下:

$$A_i^k = \begin{cases} \min\{x_{d,i}\} \quad (d = 1, 2, \dots, N_D) & \text{if } k = 1 \\ A_i^1 + (A_i^c - A_i^1) / (C - 1) * (k - 1) & \text{if } k \neq 1 \wedge k \neq C \\ \max\{x_{d,i}\} \quad (d = 1, 2, \dots, N_D) & \text{if } k = C \end{cases} \quad \text{公式(5-16)}$$

式中, $x_{d,i}$ 指代第 d 个样本的第 i 个属性值。

(4) 分类结果的评价等级 D_c 取值为:

$$D_c = c \quad (c = 1, 2, \dots, C) \quad \text{公式(5-17)}$$

(5) 第 k 条规则中的第 c 个结果的评价等级的置信值 $\beta_{c,k}$ 采用随机取初始值然后进行归一化的操作,具体取值如下:

$$\beta_{c,k} = \frac{rand^c()}{\sum_{i=1}^C rand^i()} \quad \text{公式(5-18)}$$

5.4.2 实验结果

为了验证本章方法在分类问题中的适用性,在对表 5-1 中的 UCI 分类数据集展开实验时,在 BRB 系统的生成阶段,分别生成不同数量的 BRB 系统:25 个、100 个和 200 个。进而将本章提出基于不同数量的 BRB 系统集的 SEL 学习方法与现有的其他方法进行对比,其中 Naive Bayes, C4.5 均为经典的单个分类器,EBRB-Vote 是采用扩展 BRB 推理方法由 AdaBoost 算法进行训练后集成求得结果,BRBCS-Vote 是采用多数投票法对所有 BRB 系统进行集成推理的方法,BRBCS-PAES 则是引入 Pareto 存档进化算法(Pareto Archived Evolutionary Strategy, PAES)^[57]提出的基于 PAES 的选择性集成学习方法,两者都是通过线性方式构建 BRBCS 的推理方法,BRBCS-DSEL 是本章所提的基于动态选择性集成学习的推理方法。

表 5-2 不同分类器数目下本章方法的推理准确率与其他方法加以比较

方法 \ 数据集	Cancer	Glass	Iris
Naive Bayes	95.90%	42.90%	94.71%
C4.5	96.00%	67.90%	95.13%
EBRB-Vote	93.58%	86.21%	98.60%
BRBCS - Vote(25)	95.46%	66.35%	96.00%
BRBCS - Vote(100)	95.43%	63.56%	94.10%
BRBCS - Vote(200)	93.84%	61.86%	84.67%
BRBCS- PAES(25)	96.99%	69.30%	98.82%
BRBCS- PAES(100)	97.99%	70.18%	98.85%
BRBCS- PAES(200)	97.69%	71.64%	99.38%
BRBCS - DSEL(25)	97.29%	70.04%	98.88%
BRBCS - DSEL(100)	97.99%	71.32%	99.23%
BRBCS - DSEL(200)	97.82%	71.86%	99.42%

上述的表格对比结果表明,本章引入的动态选择性集成学习方法在 BRB 分类系统数量为 25、100、200 时都得到了较优的推理分类结果。相对于采用 PAES 的选择性集成学习方法能够取得较优的结果验证了动态选择性集成学习在针对个别难以预测类别的样本时,能够做出具有针对性的选择推理,进而相对静态选

择的方法取得了更进一步的推理精度。而 EBRB 推理的方法虽然在部分数据集中取得了更优的结果,但其只能适用于较小规模的数据,整体的运行效率较低,当数据规模增大时,生成的规则数将变得非常庞大,难以进行规则的搜索与推理过程。综上所述可知本章结合动态选择性集成学习的方法在不同的分类数据集中都能够取得较好的推理结果。

5.5 本章结语

本章针静态选择性集成学习过程中没有充分利用样本自身的特征,而对于部分样本无法得到较好预测结果的问题,引入动态选择性集成学习方法。对于每个未知样本,寻找训练样本中类似的个体,采用对这些个体预测效果较好的 BRB 系统集进行推理,从而提升整体的推理性能。最后由 UCI 中的分类数据集展开实验分析,表明了基于动态选择性集成学习的置信规则库推理方法具有一定的适用性。

结论与展望

在现实中的分类或者回归问题中,人们能够得到的数据常常是模糊或缺失的,为了解决这一类的问题, Yang 等在传统 IF-THEN 规则的基本框架上加以改进,提出了基于证据理论的 BRB 推理方法和 BRB 的参数优化模型。但到目前为止,系统实现过于复杂、收敛效率不佳以及易早熟收敛等问题依旧没能被很好的解决。而后通过对选择性集成学习的研究发现,多个 BRB 系统进行推理时能够取得更好的稳定性及推理性能,而对多个系统进行筛选能够进一步提升系统性能。综上所述,关于参数训练方法与选择性集成学习的研究对 BRB 系统推理性能的提升具有重要的意义。本文开展的具体研究工作如下:

(1)为了提高 BRB 系统的性能,必须对 BRB 系统的参数加以优化。通过研究现有的参数训练方法,分析现有方法的优缺点,在此基础上提出一种基于群智能算法的参数训练方法,结合布谷鸟搜索算法,针对算法中 Levy 飞行存在的缺陷,引入自适应因子进行改进,最终训练并选取更优的参数以使得 BRB 系统拥有更好的性能。通过函数拟合和输油管道检漏两个实验,验证了算法具有更好的性能。

(2)研究 BRB 系统的选择性集成学习方法在回归问题上的应用与改进。单个置信规则库在进行推理时,系统泛化性能不够全面,而集成学习将所有训练得到 BRB 系统都参与到预测中,对比单个 BRB 系统取得了更好的性能,但是当 BRB 系统的数量增大到一定程度后,整体的推理效率将极大地降低。因此引入选择性集成学习的思想,根据设定的误差值衡量 BRB 系统的优劣程度,进而选取其中较为优秀的 BRB 系统子集应用于最终回归问题的集成推理,最后由实验结果验证 BRB 选择性集成学习推理的可行性。

(3)研究 BRB 系统的动态选择性集成学习方法在分类问题上的应用。针对 BRB 系统中出现的“组合爆炸”问题,运用线性的方式生成置信规则库,同时针对静态选择性集成学习方法没有充分利用样本自身特征的缺陷,引入动态选择性集成学习的思想,对于每个未知样本,寻找训练样本中类似的个体,采用对这些个体预测效果较好的 BRB 系统子集进行推理,以此优化并提高 BRB 系统选择性集成学习的性能。最后采用 UCI 的分类数据集加以实验分析,并与其它现有方法加以对比,表明该方法拥有更好的推理性能。

在上述研究的基础上,未来的研究方向如下:

(1)本文结合选择性集成学习的思想,对 BRB 系统的推理性能进行了一定的改进,但本文采用的基学习器均为 BRB 系统,均为同构的基学习器,为了进一

步得到具有较大差异性的基学习器,对于同一问题可以引入决策树、支持向量机、人工神经网络等适用性较强的异构的基学习器进行集成预测。如何进行异构基学习器的生成及筛选方法是下一步的研究方向。

(2)在 BRB 系统中,对于整体性能有着重要影响的部分,除了 BRB 系统的参数设置,还有 BRB 系统的构建结构,针对 BRB 选择性集成学习方法的结构不够理想的问题,如何对整体结构进行调整进而提高置信规则库推理性能是下一步的研究方向。

(3) 本文对于选择性集成学习融合阶段的研究主要在于选择阶段的静态与动态的选择方式,而现有的关于选择性集成学习的研究还可以从其他方面切入,如衡量基学习器的优劣程度的方法不只有预测值与真实值的误差,还可以考虑到当前已选取的基学习器之间的差异性,如何更好地选取合适的基学习器子集将是未来将要进行的进一步研究方向。

参考文献

- [1] Dempster A P. A generalization of Bayesian inference[J]. Journal of the Royal Statistical Society-Series B, 1968, 30(2): 205-247.
- [2] Shafer G. A mathematical theory of evidence[M]. Princeton: Princeton University Press, 1976.
- [3] Huang C L, Yong K. Multiple Attribute Decision Making Methods and Applications, A State-of Art Survey[M]. Berlin: Springer-Verlag, 1981.
- [4] Zadeh L Z. Fuzzy Sets[J]. Information and Control, 1965, 8(3): 338-353.
- [5] Sun R. Robust reasoning: integrating rule-based and similarity-based reasoning[J]. Artificial Intelligence, 1995, 75(2): 241-295.
- [6] 周志杰,杨剑波,胡昌华,徐冬玲. 置信规则库专家系统与复杂系统建模:第 1 版[M]. 科学出版社,2011.
- [7] Liu J, Yang J B, Ruan D, et al. Self-tuning of fuzzy belief rule bases for engineering system safety analysis[J]. Annals of Operations Research, 2008, 163(1): 143-168.
- [8] Zhou Z J, Hu C H, Yang J B, et al. Online updating belief rule based system for pipeline leak detection under expert intervention [J]. Expert Systems with Applications, 2009, 36(4): 7700-7709.
- [9] Yang J B, Liu J, Xu D L, et al. Optimization models for training belief-rule-based systems[J]. IEEE Transactions on systems, Man, and Cybernetics-part A: Systems and Humans, 2007, 37(4): 569-585.
- [10] 马昌凤. 最优化方法及其 Matlab 程序设计[M]. 北京: 科学出版社, 2010.
- [11] 吴伟昆, 杨隆浩, 傅仰耿, 等. 基于加速梯度求法的置信规则库参数训练方法[J]. 计算机科学与探索, 2014, 8(8): 989-1001.
- [12] 苏群, 杨隆浩, 傅仰耿, 等. 基于变速粒子群优化的置信规则库参数训练方法[J]. 计算机应用, 2014, 34(8):2161-2165.
- [13] 王韩杰, 杨隆浩, 傅仰耿, 等. 专家干预下置信规则库参数训练的差分进化算法[J]. 计算机科学, 2015, 42(5): 88-93.
- [14] 杨慧,吴沛泽,倪继良. 基于改进粒子群置信规则库参数训练算法[J]. 计算机工程与设计,2017,(02):400-404.
- [15] Keams M, Valiant L G. Learning Boolean formulae or factoring [J]. Aiken Computation Laboratory, 1988.
- [16] Hampshire J B, Waibel A H. A novel objective function for improved phoneme recognition using time-delay neural networks [J]. IEEE Transactions on Neural Networks, 1990, 1(2): 216-228.
- [17] Sharkey A J C, Sharkey N E, Cross S S. Adapting an ensemble approach for the diagnosis of breast cancer [M]//ICANN 98. Springer London, 1998: 281-286.

- [18] Schapire R E, Singer Y, Singhal A. Boosting and Rocchio applied to text filtering[C]//Proceedings of the 21st annual international ACM SIGIR conference on Research and development in information retrieval. ACM, 1998: 215-223.
- [19] Zhou Zhihua, Wu Jianxin, Tang Wei. Ensembling neural networks: many could be better than all [J]. Artificial intelligence, 2002, 137(1): 239-263.
- [20] P.Sollich, A. Krogh, Learning with ensembles: how over-fitting can be useful, in: D.S. Touretzky, M.C.Mozer, M.E. Hasselmo (Eds.), Advances in Neural Information Processing Systems 8, Denver, CO, MITPress, Cambridge, MA, 1996, pp.190-196.
- [21] D.Opitz,R.Maclin,Popular ensemble methods: an empirical study, Journal of Artificial Intelligence Research 11 (1999) 169-198.
- [22] Chen Y W, Yang J B, Xu D L, et al. Inference analysis and adaptive training for belief rule based systems[J]. Expert Systems with Applications, 2011, 38(10): 12845-12860.
- [23] 常瑞, 王红卫, 杨剑波. 基于梯度法和二分法的置信规则库参数训练方法[J]. 系统工程, 2007, 25(增刊): 287-291.
- [24] Chang L, Zhou Y, Jiang J, et al. Structure learning for belief rule base expert system: A comparative study [J]. Knowledge-Based Systems, 2013, 39: 159-172.
- [25] Calzada A, Liu J, Wang H, et al. Dynamic rule activation for extended belief rule bases[C]//Machine Learning and Cybernetics (ICMLC), 2013 International Conference on. IEEE, 2013, 4: 1836-1841.
- [26] Chang L, Zhou Z J, You Y, et al. Belief rule based expert system for classification problems with new rule activation and weight calculation procedures[J]. Information Sciences, 2016, 336: 75-91.
- [27] 叶青青,杨隆浩,傅仰耿等.基于改进置信规则库推理的分类方法[J].计算机科学与探索, 2016, 10(5): 709-721.
- [28] 王应明, 杨隆浩, 常雷雷, 傅仰耿. 置信规则库规则约简的粗糙集方法[J]. 控制与决策, 2014(11):1943-1950.
- [29] Liu J, Martinez L, Calzada A, et al. A novel belief rule base representation, generation and its inference methodology [J]. Knowledge-Based Systems, 2013, 53: 129-141.
- [30] 方志坚,杨隆浩,傅仰耿,陈建华. 基于置信规则库推理的多属性双边匹配决策方法[J]. 南京大学学报(自然科学),2016,52(04):672-681.
- [31] 方志坚,傅仰耿,陈建华. 纹理图像分类的置信规则库推理方法[J]. 应用科学学报,2017,35(05):545-558.
- [32] 吴伟昆,傅仰耿,苏群,吴英杰,巩晓婷. 基于 GDA 的置信规则库参数训练的集成学习方法 [J]. 计算机科学与探索,2016,10(12):1651-1661.
- [33] Zhou Zhihua, Wu Jianxin, Tang Wei, et al. Combining regression estimators: GA-based selective neural network ensemble [J]. International Journal of Computational Intelligence and Applications, 2001, 1(04): 341-356.

- [34] Zhou Zhihua, Wu Jianxin, Tang Wei. Ensembling neural networks: many could be better than all [J]. Artificial intelligence, 2002, 137(1): 239-263.
- [35] Lazarevic A, Obradovic Z. Effective pruning of neural network classifier ensembles//Proceedings of International Joint Conference on Neural Networks. Washington DC, 2001: 796-801.
- [36] Martinez-Munoz G, Suarez A. Using boosting to prune bagging ensembles. Pattern Recognition Letters, 2007, 28(1): 156-165.
- [37] Rokach L, Collective-agreement-based pruning of ensembles. Computational Statistics & Data Analysis, 2009, 53(4): 1015-1026.
- [38] Zhang C X, Zhang J S, Zhang G Y. Using boosting to prune double-bagging ensembles[J]. Computational Statistics & Data Analysis, 2009, 53(4): 1218-1231.
- [39] Margineantu D D, Dietterich T G. Pruning adaptive boosting//Proceedings of the 14th International Conference on Machine Learning. San Francisco, Morgan Kaufmann, 1997: 211-218.
- [40] Tamon C, Xiang J. On the boosting pruning problem//Proceedings of the 11th European Conference on Machine Learning, Catalonia, Spain, 2000: 404-412.
- [41] Caruana R, Niculescu-Mizil A, Crew G, Ksikes A. Ensemble selection from libraries of models//Proceedings of the 21st International Conference on Machine Learning, Banff, Canada, 2004: 137-144.
- [42] Ting K M, Witten I H. Issues in stacked generalization. Journal of Artificial Intelligence Research, 1999, 10: 271-289.
- [43] Soares R G, Santana A, Canuto A M, et al. Using accuracy and diversity to select classifiers to build ensembles[C]//Neural Networks, 2006. IJCNN'06. International Joint Conference on. 2006: 1310-1316.
- [44] Ko A H, Sabourin R, Britto Jr A S. From dynamic classifier selection to dynamic ensemble selection[J]. Pattern Recognition, 2008, 41(5): 1718-1731.
- [45] Dos Santos E M, Sabourin R, Maupin P. A dynamic overproduce-and-choose strategy for the selection of classifier ensembles[J]. Pattern Recognition, 2008, 41(10):2993-3009.
- [46] 王丽丽,苏德富.基于群体智能的选择性决策树分类器集成[J].计算机技术与发展,2006, 16(12): 55-57.
- [47] Xiao J, He C, Jiang X, et al. A dynamic classifier ensemble selection approach for noise data[J]. Information Sciences, 2010, 180(18): 3402-3421.
- [48] X. Wang, C. Yang, and J. Zhou. Clustering aggregation by probability accumulation, presented at Pattern Recognition, 2009, 668-675.
- [49] Hu Changhua, Si Xiaosheng, Yang Jianbo. Dynamic evidential reasoning algorithm for systems reliability prediction [J]. International Journal of Systems Science, 2010, 41(7): 783-796.
- [50] Wang Yingming, Yang Jianbo, Xu Dongling, et al. Consumer preference prediction by using a

- hybrid evidential reasoning and belief rule-based methodology[J]. Expert Systems with Applications, 2009, 36(4): 8421-8430.
- [51] Yang Jianbo, Wang Yingming, Xu Dongling, et al. Belief rule-based methodology for mapping consumer preferences and setting product targets[J]. Expert Systems with Applications, 2012, 39(5): 4749-4759.
- [52] Yang X S, Deb S. Cuckoo search via Levy flights[C]// proceedings of World Congress on nature & Biologically Inspired Computing, India, USA: IEEE Publications, 2009:210-214.
- [53] Yang X S, DEB S. Engineering optimization by cuckoo search [J]. Int'l Journal of Mathematical Modeling and Numerical Optimization, 2010, 1 (4): 330-343.
- [54] Chang Rui, Wang Weihong, Yang Jianbo. An algorithm for training parameters in belief rule-bases based on the gradient and dichotomy methods [J]. Journal of Systems Engineering, 2007, 25(supplement): 287-291.
- [55] Price, K., Differential Evolution vs. the functions of the 2nd ICEO[J], in Proceedings of the 1997 IEEE International Conference of Evolutionary Computation, 1997: 153-157.
- [56] Xu D L, Liu J, Yang J B, et al. Inference and learning methodology of belief-rule-based expert system for pipeline leak detection [J]. Expert Systems with Applications, 2007, 32(1): 103-113.
- [57] Knowles J, Corne D. The Pareto archived evolution strategy: A new baseline algorithm for Pareto multiobjective optimization[J]. Proc Congress on Evolutionary Computation, 1999.

在学期间的研究成果以及发表的学术论文

在读期间已发表和录用的论文：

第一作者（1 篇）：

【1】 置信规则库参数训练的布谷鸟搜索算法.小型微型计算机系统, 录用

参与的科研项目及成果：

【1】 国家自然科学基金项目（71501047，61773123）

【2】 福建省自然科学基金项目（2015J01248）